

# Algorytmy eksploracji danych: Wykład 3

Copyright by Wojciech Kempa

Politechnika Śląska  
Wydział Matematyki Stosowanej

# Metody szacowania zmienności wspólnej (1)

- Aby zbudować model analizy czynnikowej dla układu zmiennych obserwacyjnych  $X_1, \dots, X_p$  konieczne jest oszacowanie elementów macierzy  $A$  (czyli tzw. ładunków czynnikowych), tworzących w konsekwencji tzw. **zasoby zmienności wspólnej**, a także wariancji **czynników swoistych**, czyli elementów  $\Psi_1, \dots, \Psi_p$ .

Copyright by Wojciech Kempa

# Metody szacowania zmienności wspólnej (1)

- Aby zbudować model analizy czynnikowej dla układu zmiennych obserwacyjnych  $X_1, \dots, X_p$  konieczne jest oszacowanie elementów macierzy  $A$  (czyli tzw. ładunków czynnikowych), tworzących w konsekwencji tzw. **zasoby zmienności wspólnej**, a także wariancji **czynników swoistych**, czyli elementów  $\Psi_1, \dots, \Psi_p$ .
- Istotne w budowie modelu analizy czynnikowej jest, by zasób zmienności wspólnej stanowił jak największą część wariancji całkowitej danej zmiennej (wówczas zmenna ta jest „wyjaśniana” w dużym stopniu przez zestaw czynników wspólnych  $F_1, \dots, F_k$ ). Dążymy zatem do zmarginalizowania czynników swoistych każdej zmiennej.

# Metody szacowania zmienności wspólnej (1)

- Aby zbudować model analizy czynnikowej dla układu zmiennych obserwacyjnych  $X_1, \dots, X_p$  konieczne jest oszacowanie elementów macierzy  $A$  (czyli tzw. ładunków czynnikowych), tworzących w konsekwencji tzw. **zasoby zmienności wspólnej**, a także wariancji **czynników swoistych**, czyli elementów  $\Psi_1, \dots, \Psi_p$ .
- Istotne w budowie modelu analizy czynnikowej jest, by zasób zmienności wspólnej stanowił jak największą część wariancji całkowitej danej zmiennej (wówczas zmenna ta jest „wyjaśniana” w dużym stopniu przez zestaw czynników wspólnych  $F_1, \dots, F_k$ ). Dążymy zatem do zmarginalizowania czynników swoistych każdej zmiennej.
- Ich obecność sprawia, że na głównej przekątnej macierzy współczynników korelacji  $R$  pomiędzy wyjściowymi zmiennymi (również macierzy kowariancji  $S$ , ponieważ zmienne są zestandardyzowane) znajdują się jedynki (odpowiadające doskonałej korelacji każdej ze zmiennych ze sobą).

Gdyby nie brać pod uwagę czynników swoistych, otrzymamy tzw. **zredukowaną macierz współczynników korelacji**  $\tilde{R}$  postaci

$$\tilde{R} \stackrel{\text{def}}{=} \begin{bmatrix} h_1^2 & r_{1,2} & \dots & r_{1,p} \\ r_{2,1} & h_2^2 & \dots & r_{2,p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p,1} & r_{p,2} & \dots & h_p^2 \end{bmatrix},$$

Copyright by Wojciech Kempa

gdzie  $r_{i,j}$  oznacza współczynnik korelacji pomiędzy zmiennymi  $X_i$  oraz  $X_j$ .

Na głównej przekątnej macierzy  $\tilde{R}$  znajdują się zasoby zmienności wspólnej, natomiast pozostałe jej elementy są równe współczynnikom korelacji pomiędzy wyjściowymi zmiennymi.

Zauważmy, że prawdziwy jest teraz następujący wzór:

$$\tilde{R} = A \cdot A^T, \quad (1)$$

a zatem dla zredukowanej macierzy korelacji model analizy czynnikowej możemy zapisać w postaci macierzowej w następujący sposób:

Copyright by Wojciech Kempa

$$\mathbf{X}' = A \cdot \mathbf{F},$$

gdzie  $\mathbf{X}'$  jest wektorem zmiennych  $X_1, \dots, X_p$ , dla których nie uwzględniamy wpływu czynników swoistych.

Aby próbować oszacować elementy macierzy  $A$  korzystając z równania (1), konieczna jest znajomość zredukowanej macierzy korelacji  $\tilde{R}$ . Tu z kolei oszacowania wymagają elementy  $h_i^2$  znajdujące się na głównej przekątnej (współczynniki korelacji  $r_{i,j}$  estymujemy na podstawie próby losowej).

W literaturze proponuje się kilka różnych metod szacowania zasobów zmienności wspólnej  $h_i^2$ .

- **Metoda triad:** w metodzie tej przyjmujemy  $h_i^2 = \frac{r_{i,j}^* r_{i,k}^*}{r_{j,k}}$ , gdzie  $r_{i,j}^*$  oraz  $r_{i,k}^*$  to dwa największe współczynniki korelacji pomiędzy zmienną  $X_i$ , a pozostałymi zmiennymi ( $i \neq j$ ,  $i \neq k$ ).

Copyright by Wojciech Kempa

W literaturze proponuje się kilka różnych metod szacowania zasobów zmienności wspólnej  $h_i^2$ .

- **Metoda triad:** w metodzie tej przyjmujemy  $h_i^2 = \frac{r_{i,j}^* r_{i,k}^*}{r_{j,k}}$ , gdzie  $r_{i,j}^*$  oraz  $r_{i,k}^*$  to dwa największe współczynniki korelacji pomiędzy zmienną  $X_i$ , a pozostałymi zmiennymi ( $i \neq j$ ,  $i \neq k$ ).
- **Metoda najsilniejszej korelacji:** w metodzie tej przyjmuje się  $h_i^2 = \max_j |r_{i,j}|$ , gdzie  $i \neq j$ .

W literaturze proponuje się kilka różnych metod szacowania zasobów zmienności wspólnej  $h_i^2$ .

- **Metoda triad:** w metodzie tej przyjmujemy  $h_i^2 = \frac{r_{i,j}^* r_{i,k}^*}{r_{j,k}}$ , gdzie  $r_{i,j}^*$  oraz  $r_{i,k}^*$  to dwa największe współczynniki korelacji pomiędzy zmienną  $X_i$ , a pozostałymi zmiennymi ( $i \neq j$ ,  $i \neq k$ ).
- **Metoda najsilniejszej korelacji:** w metodzie tej przyjmuje się  $h_i^2 = \max_j |r_{i,j}|$ , gdzie  $i \neq j$ .
- **Metoda średniej korelacji:** przyjmujemy tu  $h_i^2 = \frac{1}{p-1} \sum_{k=1}^p r_{i,k}$ .

W literaturze proponuje się kilka różnych metod szacowania zasobów zmienności wspólnej  $h_i^2$ .

- **Metoda triad:** w metodzie tej przyjmujemy  $h_i^2 = \frac{r_{i,j}^* r_{i,k}^*}{r_{j,k}}$ , gdzie  $r_{i,j}^*$  oraz  $r_{i,k}^*$  to dwa największe współczynniki korelacji pomiędzy zmienną  $X_i$ , a pozostałymi zmiennymi ( $i \neq j$ ,  $i \neq k$ ).
- **Metoda najsilniejszej korelacji:** w metodzie tej przyjmuje się  $h_i^2 = \max_j |r_{i,j}|$ , gdzie  $i \neq j$ .
- **Metoda średniej korelacji:** przyjmujemy tu  $h_i^2 = \frac{1}{p-1} \sum_{k=1}^p r_{i,k}$ .
- **Metoda korelacji wielorakiej:** wykorzystuje się w niej **współczynnik korelacji wielorakiej** pomiędzy ustaloną zmienną  $X_i$ , a pozostałymi zmiennymi wyjściowego układu.

## Metody szacowania zmienności wspólnej (5)

- Współczynnik ten wyraża łączny wpływ zmiennych  $X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_p$  na zmienną  $X_i$ . Przyjmuje on wartości z przedziału  $[0, 1]$  (im większa jego wartość, tym korelacja jest silniejsza) i jest zdefiniowany w następujący sposób:

$$R_{i,1\dots(i-1)(i+1)\dots p} \stackrel{\text{def}}{=} \sqrt{1 - \frac{|R|}{R_{i,i}}},$$

gdzie  $R_{i,i}$  jest dopełnieniem algebraicznym elementu  $r_{i,i}$  macierzy  $R$ .

## Metody szacowania zmienności wspólnej (5)

- Współczynnik ten wyraża łączny wpływ zmiennych  $X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_p$  na zmienną  $X_i$ . Przyjmuje on wartości z przedziału  $[0, 1]$  (im większa jego wartość, tym korelacja jest silniejsza) i jest zdefiniowany w następujący sposób:

$$R_{i,1\dots(i-1)(i+1)\dots p} \stackrel{\text{def}}{=} \sqrt{1 - \frac{|R|}{R_{i,i}}},$$

gdzie  $R_{i,i}$  jest dopełnieniem algebraicznym elementu  $r_{i,i}$  macierzy  $R$ .

- W metodzie korelacji wielorakiej przyjmujemy  $h_i^2 = R_{i,1\dots(i-1)(i+1)\dots p}^2$ . Metoda ta jest najczęściej stosowana w praktyce, uwzględnia ona całą macierz współczynników korelacji (jest jedyną metodą stosowaną w pakiecie STATISTICA).

- **Metoda pierwszego czynnika centroidalnego:** metoda ta również uwzględnia wszystkie elementy macierzy korelacji  $R$ ,

Przyjmujemy w niej 
$$h_i^2 = \frac{\left( \sum_{k=1}^p r_{i,k} \right)^2}{\sum_{j=1}^p \sum_{k=1}^p r_{j,k}}$$

Wyodrębnienie ładunków wspólnych jest związane ze znalezieniem nowego układu współrzędnych, który zastąpi  $p$ -wymiarowy układ wyjściowy. Do najważniejszych metod szacowania ładunków wspólnych należą:

- **metoda centroidalna;**  
Copyright by Wojciech Kempa
- **metoda składowych głównych;**
- **metoda największej wiarygodności.**

Omówimy w szczegółach metodę centroidalną oraz metodę składowych głównych.

# Metoda centroidalna (1)

- Podstawową i najstarszą zarazem metodą wyodrębniania łączników wspólnych, zaprezentowaną przez L. Thurstone'a w 1947 roku, jest **metoda centroidalna**, zwana także **metodą środków ciężkości**.

Copyright by Wojciech Kempa

# Metoda centroidalna (1)

- Podstawową i najstarszą zarazem metodą wyodrębniania łączników wspólnych, zaprezentowaną przez L. Thurstone'a w 1947 roku, jest **metoda centroidalna**, zwana także **metodą środków ciężkości**.
- Wektory reprezentujące wariancje zmiennych  $X_1, \dots, X_p$  mają swój początek w początku  $O$  układu współrzędnych (są równoległe do odpowiednich osi tego układu). Ich końce natomiast wyznaczają środek ciężkości  $S_1$  układu wektorów.

Copyright by Wojciech Kempa

# Metoda centroidalna (1)

- Podstawową i najstarszą zarazem metodą wyodrębniania łączników wspólnych, zaprezentowaną przez L. Thurstone'a w 1947 roku, jest **metoda centroidalna**, zwana także **metodą środków ciężkości**.
- Wektory reprezentujące wariancje zmiennych  $X_1, \dots, X_p$  mają swój początek w początku  $O$  układu współrzędnych (są równoległe do odpowiednich osi tego układu). Ich końce natomiast wyznaczają środek ciężkości  $S_1$  układu wektorów.
- Pierwsza oś nowego układu współrzędnych (odpowiadająca czynnikowi  $F_1$ ) będzie przechodzić przez punkt  $O$  oraz punkt  $S_1$  będący środkiem ciężkości.

# Metoda centroidalna (1)

- Podstawową i najstarszą zarazem metodą wyodrębniania ładunków wspólnych, zaprezentowaną przez L. Thurstone'a w 1947 roku, jest **metoda centroidalna**, zwana także **metodą środków ciężkości**.
- Wektory reprezentujące wariancje zmiennych  $X_1, \dots, X_p$  mają swój początek w początku  $O$  układu współrzędnych (są równoległe do odpowiednich osi tego układu). Ich końce natomiast wyznaczają środek ciężkości  $S_1$  układu wektorów.
- Pierwsza oś nowego układu współrzędnych (odpowiadająca czynnikowi  $F_1$ ) będzie przechodzić przez punkt  $O$  oraz punkt  $S_1$  będący środkiem ciężkości.
- Po utworzeniu zredukowanej macierzy korelacji  $\tilde{R}$ , sumujemy wartości występujące w poszczególnych kolumnach tej macierzy. Dla  $i$ -tej kolumny otrzymujemy następującą sumę:

$$T_i \stackrel{\text{def}}{=} r_{1,i} + \dots + r_{i-1,i} + h_i^2 + r_{i+1,i} + \dots + r_{p,i}.$$

## Metoda centroidalna (2)

Niech  $T \stackrel{def}{=} \sum_{i=1}^p T_i$ . Wartość pierwszego ładunku czynnikowego dla zmiennej  $X_i$  obliczamy ze wzoru

$$a_{i,1} = \frac{T_i}{\sqrt{T}}.$$

Po obliczeniu wartości ładunków pierwszego czynnika  $F_1$ , wyodrębniamy wielkości  $a_{i,2}$ , czyli ładunki czynnika  $F_2$ . Definiujemy macierz  $R_1$  pierwszych pozostałości zredukowanej macierzy korelacji  $\tilde{R}$  (tzw. **macierz rezydualną**) w następujący sposób:

$$R_1 \stackrel{def}{=} \tilde{R} - Q_1,$$

gdzie

$$Q_1 \stackrel{def}{=} \begin{bmatrix} a_{1,1}^2 & a_{1,1}a_{2,1} & \dots & a_{1,1}a_{p,1} \\ a_{2,1}a_{1,1} & a_{2,1}^2 & \dots & a_{2,1}a_{p,1} \\ \vdots & \vdots & \ddots & \vdots \\ a_{p,1}a_{1,1} & a_{p,1}a_{2,1} & \dots & a_{p,1}^2 \end{bmatrix}.$$

## Metoda centroidalna (3)

- Jak wiemy, obliczając ładunki dla pierwszego czynnika  $F_1$ , poprowadziliśmy oś pierwszego czynnika przez środek ciężkości wyznaczony przez końce wektorów reprezentujących wariancje zmiennych  $X_1, \dots, X_p$ .

Copyright by Wojciech Kempa

## Metoda centroidalna (3)

- Jak wiemy, obliczając ładunki dla pierwszego czynnika  $F_1$ , poprowadziliśmy oś pierwszego czynnika przez środek ciężkości wyznaczony przez końce wektorów reprezentujących wariancje zmiennych  $X_1, \dots, X_p$ .
- Usunięcie części wariancji wspólnej związanej z pierwszym czynnikiem spowoduje przesunięcie punktu  $O$  w miejsce punktu  $S_1$  wzduł osi pierwszego czynnika.

## Metoda centroidalna (3)

- Jak wiemy, obliczając ładunki dla pierwszego czynnika  $F_1$ , poprowadziliśmy oś pierwszego czynnika przez środek ciężkości wyznaczony przez końce wektorów reprezentujących wariancje zmiennych  $X_1, \dots, X_p$ .
- Usunięcie części wariancji wspólnej związanej z pierwszym czynnikiem spowoduje przesunięcie punktu  $O$  w miejsce punktu  $S_1$  wzduł osi pierwszego czynnika.
- Otrzymamy oś drugiego czynnika  $F_2$ , która jest prostopadła do osi pierwszego czynnika i przechodzi przez punkt  $O = S_1$ .

- Jak wiemy, obliczając ładunki dla pierwszego czynnika  $F_1$ , poprowadziliśmy oś pierwszego czynnika przez środek ciężkości wyznaczony przez końce wektorów reprezentujących wariancje zmiennych  $X_1, \dots, X_p$ .
- Usunięcie części wariancji wspólnej związanej z pierwszym czynnikiem spowoduje przesunięcie punktu  $O$  w miejsce punktu  $S_1$  wzdłuż osi pierwszego czynnika.
- Otrzymamy oś drugiego czynnika  $F_2$ , która jest prostopadła do osi pierwszego czynnika i przechodzi przez punkt  $O = S_1$ .
- Łączymy teraz końce początkowych wektorów z punktem  $S_1$ .  
Nowo powstałe wektory są krótsze od wektorów początkowych, co jest związane z usunięciem części wariancji wspólnej związanej z czynnikiem  $F_1$ .

- Sumy współczynników występujących w każdej z kolumn macierzy  $R_1$  są bardzo bliskie zeru. Korespondują one z odległościami końców „nowych” wektorów od początku  $S_1$  „nowego” układu. Niektóre sumy mogą być dodatnie, inne ujemne.

Copyright by Wojciech Kempa

## Metoda centroidalna (4)

- Sumy współczynników występujących w każdej z kolumn macierzy  $R_1$  są bardzo bliskie zeru. Korespondują one z odległościami końców „nowych” wektorów od początku  $S_1$  „nowego” układu. Niektóre sumy mogą być dodatnie, inne ujemne.
- Aby otrzymać dodatnie sumy w kolumnach macierzy  $R_1$ , wykorzystujemy rekurencyjną, dość skomplikowaną, procedurę. Jej efektem jest zmiana zwrotu (bez zmiany długości) niektórych wektorów reprezentujących wariancje zmiennych pozostałe do wyjaśnienia po „odjęciu” części wyjaśnionej przez  $F_1$ .

- Sumy współczynników występujących w każdej z kolumn macierzy  $R_1$  są bardzo bliskie zeru. Korespondują one z odległościami końców „nowych” wektorów od początku  $S_1$  „nowego” układu. Niektóre sumy mogą być dodatnie, inne ujemne.
- Aby otrzymać dodatnie sumy w kolumnach macierzy  $R_1$ , wykorzystujemy rekurencyjną, dość skomplikowaną, procedurę. Jej efektem jest zmiana zwrotu (bez zmiany długości) niektórych wektorów reprezentujących wariancje zmiennych pozostałe do wyjaśnienia po „odjęciu” części wyjaśnionej przez  $F_1$ .
- W konsekwencji wszystkie wektory znajdą się teraz po jednej i tej samej stronie osi pierwszego czynnika  $F_1$ .

- W nowo otrzymanej w ten sposób macierzy  $R_1$  sumujemy elementy w poszczególnych kolumnach. Otrzymujemy nową wartość  $T_i$  dla  $i$ -tej kolumny tej macierzy.

Copyright by Wojciech Kempa

- W nowo otrzymanej w ten sposób macierzy  $R_1$  sumujemy elementy w poszczególnych kolumnach. Otrzymujemy nową wartość  $T_i$  dla  $i$ -tej kolumny tej macierzy.
- Przyjmując, podobnie jak poprzednio,  $T = \sum_{i=1}^p T_i$ , ładunek drugiego czynnika obliczamy ze wzoru

$$a_{i,2} = \frac{T_i}{\sqrt{T}}.$$

- Na końcu należy jeszcze sprawdzić, jaki znak będzie miała wartość  $i$ -tego ładunku.

Copyright by Wojciech Kempa

## Metoda centroidalna (6)

- Na końcu należy jeszcze sprawdzić, jaki znak będzie miała wartość  $i$ -tego ładunku.
- Jeżeli w procedurze rekurencyjnej zmienna  $X_i$  była odwracana parzystą ilość razy (w szczególności wcale), to znak jej drugiego ładunku czynnikowego jest taki sam, jak znak poprzedniego (tu: pierwszego) ładunku.

Copyright by Wojciech Kempa

## Metoda centroidalna (6)

- Na końcu należy jeszcze sprawdzić, jaki znak będzie miała wartość  $i$ -tego ładunku.
- Jeżeli w procedurze rekurencyjnej zmienna  $X_i$  była odwracana parzystą ilość razy (w szczególności wcale), to znak jej drugiego ładunku czynnikowego jest taki sam, jak znak poprzedniego (tu: pierwszego) ładunku.
- Jeżeli zmienna ta była odwracana nieparzystą ilość razy, to jej drugi ładunek czynnikowy będzie miał przeciwny znak do ładunku pierwszego.

Copyright by Wojciech Kempa

## Metoda centroidalna (6)

- Na końcu należy jeszcze sprawdzić, jaki znak będzie miała wartość  $i$ -tego ładunku.
- Jeżeli w procedurze rekurencyjnej zmienna  $X_i$  była odwracana parzystą ilość razy (w szczególności wcale), to znak jej drugiego ładunku czynnikowego jest taki sam, jak znak poprzedniego (tu: pierwszego) ładunku.
- Jeżeli zmienna ta była odwracana nieparzystą ilość razy, to jej drugi ładunek czynnikowy będzie miał przeciwny znak do ładunku pierwszego.
- W kolejnym kroku wyznaczamy macierz pozostałości macierzy korelacji po wyodrębnieniu drugiego czynnika  $F_2$  i wyznaczamy wartości kolejnych ładunków czynnikowych, stosując powyższą procedurę.

# Metoda składowych głównych (1)

- W metodzie tej przyjmujemy, że  $\tilde{R} = R$ , czyli zakładamy, że wariancje swoiste są równe zeru.

Copyright by Wojciech Kempa

- W metodzie tej przyjmujemy, że  $\tilde{R} = R$ , czyli zakładamy, że wariancje swoiste są równe zeru.
- Model analizy czynnikowej redukuje się wówczas do postaci

$$\mathbf{X} = A \cdot \mathbf{F}.$$

Copyright by Wojciech Kempa

- W metodzie tej przyjmujemy, że  $\tilde{R} = R$ , czyli zakładamy, że wariancje swoiste są równe zeru.
- Model analizy czynnikowej redukuje się wówczas do postaci

$$\mathbf{X} = A \cdot \mathbf{F}.$$

- Copyright by Wojciech Kempa
- Dalej postępujemy tak, jak w klasycznej metodzie PCA. Wyznaczamy wartości własne macierzy korelacji  $R$ , rozwiązuając równanie charakterystyczne  $|R - \lambda \mathbb{E}| = 0$ .

- W metodzie tej przyjmujemy, że  $\tilde{R} = R$ , czyli zakładamy, że wariancje swoiste są równe zeru.
- Model analizy czynnikowej redukuje się wówczas do postaci

$$\mathbf{X} = A \cdot \mathbf{F}.$$

Copyright by Wojciech Kempa

- Dalej postępujemy tak, jak w klasycznej metodzie PCA. Wyznaczamy wartości własne macierzy korelacji  $R$ , rozwiązuając równanie charakterystyczne  $|R - \lambda \mathbb{E}| = 0$ .
- Z każdą wartością własną  $\lambda_i$  związany jest znormalizowany wektor własny, którego współrzędne posłużą do wyznaczenia ładunków czynnikowych.

## Metoda składowych głównych (2)

- Dla  $i$ -tej z kolejnych najwiekszej wartości własnej  $\lambda_i$  mamy wówczas

$$F_i = a_{i,1}X_1 + \dots + a_{i,p}X_p. \quad (2)$$

gdzie współczynniki przy kolejnych zmiennych  $X_1, \dots, X_p$  są współrzędnymi wektora własnego odpowiadającego  $\lambda_i$ .

Copyright by Wojciech Kempa

## Metoda składowych głównych (2)

- Dla  $i$ -tej z kolejnych największej wartości własnej  $\lambda_i$  mamy wówczas

$$F_i = a_{i,1}X_1 + \dots + a_{i,p}X_p. \quad (2)$$

gdzie współczynniki przy kolejnych zmiennych  $X_1, \dots, X_p$  są współrzędnymi wektora własnego odpowiadającego  $\lambda_i$ .

- Po wyznaczeniu ładunków czynnikowych możemy określić, jaką część (procent) całkowitej wariancji jest wyznaczona za pomocą danego czynnika wspólnego.

## Metoda składowych głównych (2)

- Dla  $i$ -tej z kolejnych najwiekszej wartości własnej  $\lambda_i$  mamy wówczas

$$F_i = a_{i,1}X_1 + \dots + a_{i,p}X_p. \quad (2)$$

gdzie współczynniki przy kolejnych zmiennych  $X_1, \dots, X_p$  są współrzędnymi wektora własnego odpowiadającego  $\lambda_i$ .

- Po wyznaczeniu ładunków czynnikowych możemy określić, jaką część (procent) całkowitej wariancji jest wyznaczona za pomocą danego czynnika wspólnego.
- Dla czynnika  $F_i$  jest ona wyrażona wzorem (korzystamy tu z faktu, że suma wariancji wszystkich zmiennych znormalizowanych wynosi  $p$ )

$$\frac{1}{p} \sum_{i=1}^p a_{i,j}^2 \cdot 100\%.$$

# Kryteria wyboru ilości czynników wspólnych (1)

Ile czynników wspólnych należy wybrać? W praktyce stosuje się tu różne kryteria, podobne do tych stosowanych w analizie składowych głównych.

- **Kryterium Kaisera:** bierzemy pod uwagę tylko te czynniki, którym odpowiadają wartości własne macierzy korelacji  $R$  większe od 1.

Copyright by Wojciech Kempa

# Kryteria wyboru ilości czynników wspólnych (1)

Ile czynników wspólnych należy wybrać? W praktyce stosuje się tu różne kryteria, podobne do tych stosowanych w analizie składowych głównych.

- **Kryterium Kaisera:** bierzemy pod uwagę tylko te czynniki, którym odpowiadają wartości własne macierzy korelacji  $R$  większe od 1.
- **Kryterium Cattella:** związane z tzw. **wykresem osypiska**, w którym bierzemy pod uwagę tylko te czynniki, którym odpowiadają wartości własne macierzy korelacji położone na lewo od punktu łagodnego spadku łamanej łączącej punkty odpowiadające kolejnym wartościom własnym (w kolejności malejącej). Sam punkt, w którym rozpoczyna się łagodny spadek możemy zaliczyć do tej grupy bądź nie.

## Kryteria wyboru ilości czynników wspólnych (2)

- **Kryterium procentowe:** zakłada pozostawienie tylko takiej ilości początkowych czynników wspólnych wyznaczonych dla układu cech, by łączny udział procentowy wyjaśnianej przez nie wariancji przekroczył pewien ustalony próg, np. 75% lub 80%.

Copyright by Wojciech Kempa

## Kryteria wyboru ilości czynników wspólnych (2)

- **Kryterium procentowe:** zakłada pozostawienie tylko takiej ilości początkowych czynników wspólnych wyznaczonych dla układu cech, by łączny udział procentowy wyjaśnianej przez nie wariancji przekroczył pewien ustalony próg, np. 75% lub 80%.
- **Kryterium „połowy”:** liczba czynników nie powinna przekroczyć wartości  $\frac{p}{2}$ , gdzie  $p$  oznacza liczbę oryginalnych zmiennych obserwowań.