

Algorytmy eksploracji danych: Wykład 5

Copyright by Wojciech Kempa

Politechnika Śląska
Wydział Matematyki Stosowanej

Wybór wymiaru przestrzeni rzutowania (1)

- Podobnie jak w przypadku analizy składowych głównych czy też analizy czynnikowej, wybór wymiaru przestrzeni rzutowania (liczby osi układu współrzędnych) jest określany za pomocą miernika udziału danej osi w wyjaśnieniu całkowitej inercji oryginalnego układu.

Copyright by Wojciech Kempa

Wybór wymiaru przestrzeni rzutowania (1)

- Podobnie jak w przypadku analizy składowych głównych czy też analizy czynnikowej, wybór wymiaru przestrzeni rzutowania (liczby osi układu współrzędnych) jest określany za pomocą miernika udziału danej osi w wyjaśnieniu całkowitej inercji oryginalnego układu.
- Ogólnie, wielkość

$$\frac{\lambda_k}{\sum_{i=1}^{rz(\mathbf{P})} \lambda_i} \cdot 100\%,$$

gdzie $rz(\mathbf{P}) = \min(r - 1, c - 1)$ oznacza rząd macierzy korespondencji, wyraża procent inercji całkowitej wyjaśniony za pomocą k -tej osi głównej (k -tego wymiaru).

Wybór wymiaru przestrzeni rzutowania (1)

- Podobnie jak w przypadku analizy składowych głównych czy też analizy czynnikowej, wybór wymiaru przestrzeni rzutowania (liczby osi układu współrzędnych) jest określany za pomocą miernika udziału danej osi w wyjaśnieniu całkowitej inercji oryginalnego układu.
- Ogólnie, wielkość

$$\frac{\lambda_k}{\sum_{i=1}^{rz(\mathbf{P})} \lambda_i} \cdot 100\%,$$

gdzie $rz(\mathbf{P}) = \min(r - 1, c - 1)$ oznacza rząd macierzy korespondencji, wyraża procent inercji całkowitej wyjaśniony za pomocą k -tej osi głównej (k -tego wymiaru).

- Jeżeli zatem np. dwie pierwsze osie główne wyjaśniają 80% inercji całkowitej, możemy poprzestać na dwuwymiarowym opisie powiązań pomiędzy kategoriami (ze stratą informacji rzędu 20%).

Wybór wymiaru przestrzeni rzutowania (2)

- Innym sposobem określania wymiaru przestrzeni rzutowania jest analiza łamanej przedstawiającej kolejne wartości własne λ_k macierzy AA^T i A^TA . W odróżnieniu od PCA i FA, stosuje się tu nazwę „**kryterium łokcia**” (ang. *the elbow criterion*) zamiast analizy wykresu osypiska.

Copyright by Wojciech Kempa

Wybór wymiaru przestrzeni rzutowania (2)

- Innym sposobem określania wymiaru przestrzeni rzutowania jest analiza łamanej przedstawiającej kolejne wartości własne λ_k macierzy AA^T i A^TA . W odróżnieniu od PCA i FA, stosuje się tu nazwę „**kryterium łokcia**” (ang. *the elbow criterion*) zamiast analizy wykresu osypiska.
- W ostatniej metodzie (zapropozował ją Greenacre w 1984 roku) jako optymalny wymiar przestrzeni rzutowania wybieramy minimalne k , dla którego spełniony jest warunek

$$\lambda_{Z,k} > \frac{1}{q},$$

gdzie $\lambda_{Z,k}$ jest k -tą największą wartością własną macierzy znaczników Z , a q oznacza liczbę analizowanych zmiennych (tu $q = 2$). Macierz znaczników Z jest tu rozumiana jako macierz, w której kolejne wiersze odpowiadają kolejnym elementom próby losowej (jest ich n), a kolumny - kolejnym kategoriom kolejnych zmiennych.

Interpretacja nowych współrzędnych (1)

- Po wyznaczeniu nowych współrzędnych można oszacować „korelację” punktu odpowiadającego danej kategorii oryginalnej cechy z którąś z osi przestrzeni rzutowania.

Copyright by Wojciech Kempa

Interpretacja nowych współrzędnych (1)

- Po wyznaczeniu nowych współrzędnych można oszacować „korelację” punktu odpowiadającego danej kategorii oryginalnej cechy z którąś z osi przestrzeni rzutowania.
- Jeżeli $f_{i,k}$ jest współrzędną i -tego punktu na k -tej osi, d_i - odległością i -tego punktu od centrum rzutowania (środką nowego układu współrzędnych), natomiast $\alpha_{i,k}$ oznacza kąt pomiędzy promieniem wodzącym i -tego punktu a k -tą osią, to prawdziwy jest następujący wzór:

$$\cos^2 \alpha_{i,k} = \frac{f_{i,k}^2}{d_i^2}.$$

Interpretacja nowych współrzędnych (1)

- Po wyznaczeniu nowych współrzędnych można oszacować „korelację” punktu odpowiadającego danej kategorii oryginalnej cechy z którąś z osi przestrzeni rzutowania.
- Jeżeli $f_{i,k}$ jest współrzędną i -tego punktu na k -tej osi, d_i - odległością i -tego punktu od centrum rzutowania (środką nowego układu współrzędnych), natomiast $\alpha_{i,k}$ oznacza kąt pomiędzy promieniem wodzącym i -tego punktu a k -tą osią, to prawdziwy jest następujący wzór:

$$\cos^2 \alpha_{i,k} = \frac{f_{i,k}^2}{d_i^2}.$$

- Wielkość $\cos^2 \alpha_{i,k}$ wskazuje na stopień „wyjaśnienia” danej kategorii oryginalnej zmiennej (reprezentowanej przez i -ty punkt) przez k -tą oś główną przestrzeni rzutowania (można tę wielkość podawać również w ujęciu procentowym).

Interpretacja nowych współrzędnych (2)

Poniższe zasady są pomocne we właściwej interpretacji konkretnego położenia punktu (reprezentującego daną kategorię zmiennej) w przestrzeni rzutowania (w nowym układzie współrzędnych):

- Im bliżej centrum rzutowania położony jest dany punkt, tym bardziej jego profil jest zbliżony do profilu średniego (np. jeżeli kategoria X_2 cechy X jest położona najbliżej centrum rzutowania ze wszystkich punktów odpowiadających kategoriom cechy X , oznacza to, że kategoria ta jest najbardziej zbliżona do średniego profilu wierszowego).

Interpretacja nowych współrzędnych (2)

Poniższe zasady są pomocne we właściwej interpretacji konkretnego położenia punktu (reprezentującego daną kategorię zmiennej) w przestrzeni rzutowania (w nowym układzie współrzędnych):

- Im bliżej centrum rzutowania położony jest dany punkt, tym bardziej jego profil jest zbliżony do profilu średniego (np. jeżeli kategoria X_2 cechy X jest położona najbliżej centrum rzutowania ze wszystkich punktów odpowiadających kategoriom cechy X , oznacza to, że kategoria ta jest najbardziej zbliżona do średniego profilu wierszowego).
- Im dalej punkt jest położony od centrum rzutowania, tym większy „udział” tego punktu (czyli kategorii) w ewentualnym odrzuceniu hipotezy o niezależności cech.

- W przypadku tej samej zmiennej: bliskie względem siebie położenie punktów (np. X_1 i X_2) świadczy o podobieństwie ich profili.

Copyright by Wojciech Kempa

Interpretacja nowych współrzędnych (3)

- W przypadku tej samej zmiennej: bliskie względem siebie położenie punktów (np. X_1 i X_2) świadczy o podobieństwie ich profili.
- W przypadku różnych zmiennych: bliskie względem siebie położenie punktów (np. X_1 i Y_2) świadczy o istnieniu powiązań pomiędzy kategoriami tych zmiennych.

- W przestrzeni rzutowania (szczególnie dwuwymiarowej) można stosunkowo często zaobserwować tzw. **efekt Guttmana**, nazywany także **efektem podkowy** (ang. *horseshoe effect*), kiedy punkty odpowiadające poszczególnym kategoriom (obydwu cech) układają się w dość wyraźny łuk.

Copyright by Wojciech Kempa

- W przestrzeni rzutowania (szczególnie dwuwymiarowej) można stosunkowo często zaobserwować tzw. **efekt Guttmana**, nazywany także **efektem podkowy** (ang. *horseshoe effect*), kiedy punkty odpowiadające poszczególnym kategoriom (obydwu cech) układają się w dość wyraźny łuk.
- Efekt ten można także zaobserwować, gdy po zmianie kolejności poszczególnych kategorii cech X i Y w tablicy kontyngencji na taką, która odpowiada kolejności pojawiania się punktów w przestrzeni rzutowania po zrzutowaniu ich na pierwszą oś główną, zaobserwowane liczebności grupują się wokół „pasa” wyznaczonego przez główną przekątną tablicy.

- Efekt Guttmana świadczy o **dominacji pierwszej osi głównej**.

Copyright by Wojciech Kempa

- Efekt Guttmana świadczy o **dominacji pierwszej osi głównej**.
- Im wyraźniejszy ów łuk w przestrzeni rzutowania, tym udział pierwszej osi (współrzędnej) w wyjaśnieniu inercji całkowitej jest bliższy 100%. W konsekwencji analizę korespondencji można wówczas przeprowadzić jednowymiarowo.

Wielowymiarowa analiza korespondencji (1)

- **Wielowymiarowa analiza korespondencji** (ang. *Multiple Correspondence Analysis (MCA)*) jest przeprowadzana w sytuacji, w której obiekty opisane są za pomocą co najmniej trzech zmiennych o charakterze jakościowym.

Copyright by Wojciech Kempa

Wielowymiarowa analiza korespondencji (1)

- **Wielowymiarowa analiza korespondencji** (ang. *Multiple Correspondence Analysis (MCA)*) jest przeprowadzana w sytuacji, w której obiekty opisane są za pomocą co najmniej trzech zmiennych o charakterze jakościowym.
- Wprowadza się tu pojęcie tzw. **macierzy Burta**, zdefiniowanej w następujący sposób:

$$\mathbf{B} \stackrel{def}{=} \mathbf{Z}^T \mathbf{Z},$$

Copyright by Wojciech Kempa

gdzie \mathbf{Z} jest macierzą znaczników (wiersze odpowiadają kolejnym elementom próby losowej, a kolumny wariantom kolejnych cech).

Wielowymiarowa analiza korespondencji (1)

- **Wielowymiarowa analiza korespondencji** (ang. *Multiple Correspondence Analysis (MCA)*) jest przeprowadzana w sytuacji, w której obiekty opisane są za pomocą co najmniej trzech zmiennych o charakterze jakościowym.
- Wprowadza się tu pojęcie tzw. **macierzy Burta**, zdefiniowanej w następujący sposób:

$$\mathbf{B} \stackrel{\text{def}}{=} \mathbf{Z}^T \mathbf{Z},$$

Copyright by Wojciech Kempa

gdzie \mathbf{Z} jest macierzą znaczników (wiersze odpowiadają kolejnym elementom próby losowej, a kolumny wariantom kolejnych cech).

- Jeśli np. badane są trzy cechy: X, Y i U , to w macierzy znaczników każdy wiersz zawiera tylko trzy jedynki (na pozycjach odpowiadających kategoriom badanych cech, którymi charakteryzuje się konkretny element próby), a na pozostałych miejscach zera.

Wielowymiarowa analiza korespondencji (2)

- Łatwo sprawdzić, że macierz Burta utworzona dla trzech cech zawierać będzie dziewięć macierzy blokowych, z których każda będzie miała liczebność równą liczebności próby n .

Copyright by Wojciech Kempa

Wielowymiarowa analiza korespondencji (2)

- Łatwo sprawdzić, że macierz Burta utworzona dla trzech cech zawierać będzie dziewięć macierzy blokowych, z których każda będzie miała liczebność równą liczebności próby n .
- Całkowita liczebność macierzy Burta wynosi zatem nq^2 , gdzie q oznacza liczbę analizowanych zmiennych.

Copyright by Wojciech Kempa

Wielowymiarowa analiza korespondencji (2)

- Łatwo sprawdzić, że macierz Burta utworzona dla trzech cech zawierać będzie dziewięć macierzy blokowych, z których każda będzie miała liczebność równą liczebności próby n .
- Całkowita liczebność macierzy Burta wynosi zatem nq^2 , gdzie q oznacza liczbę analizowanych zmiennych.
- W wielowymiarowej analizie korespondencji macierz korespondencji jest zdefiniowana jako

$$\mathbf{P} = \frac{1}{nq^2} \mathbf{B},$$

zaś dekompozycji poddawana jest macierz

$$\mathbf{A} = \mathbf{D}_r^{-1/2} (\mathbf{P} - \mathbf{r} \mathbf{r}^T) \mathbf{D}_r^{-1/2}.$$

Wprowadzenie do analizy skupień (1)

- **Grupowanie**, zwane inaczej **analizą skupień** lub **klasteryzacją** (ang. *data clustering*) stanowi zbiór technik i metod, których zasadniczym celem jest wyszukiwanie (przede wszystkim w dużych zbiorach danych), a następnie łączenie ze sobą w tzw. **skupienia** (zwane także **klastrami**) obiektów „podobnych”.

Copyright by Wojciech Kempa

Wprowadzenie do analizy skupień (1)

- **Grupowanie**, zwane inaczej **analizą skupień** lub **klasteryzacją** (ang. *data clustering*) stanowi zbiór technik i metod, których zasadniczym celem jest wyszukiwanie (przede wszystkim w dużych zbiorach danych), a następnie łączenie ze sobą w tzw. **skupienia** (zwane także **klastrami**) obiektów „podobnych”.
- Utworzone w wyniku przeprowadzenia procesu grupowania skupienia powinny oczywiście być zbiorami rozłącznymi, ale także maksymalnie „oddzielonymi” od siebie, skupiającymi elementy mogące być podobnie scharakteryzowane.

Wprowadzenie do analizy skupień (1)

- **Grupowanie**, zwane inaczej **analizą skupień** lub **klasteryzacją** (ang. *data clustering*) stanowi zbiór technik i metod, których zasadniczym celem jest wyszukiwanie (przede wszystkim w dużych zbiorach danych), a następnie łączenie ze sobą w tzw. **skupienia** (zwane także **klastrami**) obiektów „podobnych”.
- Utworzone w wyniku przeprowadzenia procesu grupowania skupienia powinny oczywiście być zbiorami rozłącznymi, ale także maksymalnie „oddzielonymi” od siebie, skupiającymi elementy mogące być podobnie scharakteryzowane.
- Poszczególne obiekty podlegające procesowi klasteryzacji mogą być opisane zmiennymi różnego typu: ilościowymi, binarnymi, jakościowymi o skali porządkowej, jakościowymi opisanymi skalą nominalną.

- Jako przykład może nam posłużyć baza danych o klientach pewnego operatora telekomunikacyjnego.

Copyright by Wojciech Kempa

Wprowadzenie do analizy skupień (2)

- Jako przykład może nam posłużyć baza danych o klientach pewnego operatora telekomunikacyjnego.
- Poszczególne obiekty tej bazy (klienci) mogą być opisani np. za pomocą czterech zmiennych, zwanych **atrybutami**: X_1 - wiek, X_2 - status majątkowy, X_3 - liczba osób w gospodarstwie domowym, X_4 - miejsce zamieszkania.

Wprowadzenie do analizy skupień (2)

- Jako przykład może nam posłużyć baza danych o klientach pewnego operatora telekomunikacyjnego.
- Poszczególne obiekty tej bazy (klienci) mogą być opisani np. za pomocą czterech zmiennych, zwanych **atrybutami**: X_1 - wiek, X_2 - status majątkowy, X_3 - liczba osób w gospodarstwie domowym, X_4 - miejsce zamieszkania.
- Przykładowy obiekt może mieć zatem postać: (42, średni, 3, duże miasto), co oznacza osobę w wieku 42 lat, o średnim statusie majątkowym, której gospodarstwo domowe liczy łącznie 3 osoby, mieszkańca dużego miasta.

- Załóżmy, że operator zamierza przygotować trzy różne oferty promocyjne „dedykowane” konkretnym klientom.

Copyright by Wojciech Kempa

Wprowadzenie do analizy skupień (3)

- Załóżmy, że operator zamierza przygotować trzy różne oferty promocyjne „dedykowane” konkretnym klientom.
- Jak podzielić całą bazę danych na trzy rozłączne podzbiory tak, by móc je następnie dobrze scharakteryzować i dostosować do nich konkretną ofertę?

Wprowadzenie do analizy skupień (3)

- Załóżmy, że operator zamierza przygotować trzy różne oferty promocyjne „dedykowane” konkretnym klientom.
- Jak podzielić całą bazę danych na trzy rozłączne podzbiory tak, by móc je następnie dobrze scharakteryzować i dostosować do nich konkretną ofertę?
- W odpowiedzi na tego typu pytania pomocna jest właśnie analiza skupień.

Miary odległości obiektów (1)

W analizie skupień punktem wyjścia jest tzw. **macierz niepodobieństwa** obiektów (zwana także **macierzą odległości**). Jeżeli przyjmimy, że X_1, \dots, X_n są danymi obiektami, które zamierzamy pogrupować, ma ona następującą postać:

$$\mathbf{D} = \begin{bmatrix} 0 & D(X_1, X_2) & \dots & D(X_1, X_n) \\ D(X_2, X_1) & 0 & \dots & D(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ D(X_n, X_1) & D(X_n, X_2) & \dots & 0 \end{bmatrix},$$

w której $D(X_i, X_j)$ oznacza miarę niepodobieństwa (odległość) obiektów X_i oraz X_j . Oczywiście, \mathbf{D} jest macierzą symetryczną z zerami na głównej przekątnej.

Miary odległości obiektów (2)

Odległości $D(X_i, X_j)$ mogą być różnie definiowane. Jeżeli obiekty są opisane za pomocą atrybutów mierzalnych (ilościowych), ale nie binarnych, np. za pomocą p atrybutów, czyli w postaci $X_i = (X_{i,1}, \dots, X_{i,p})$, $X_j = (X_{j,1}, \dots, X_{j,p})$, wówczas stosuje się następujące miary:

- **odległość euklidesowa:** $D(X_i, X_j) = \sqrt{\sum_{k=1}^p (X_{i,k} - X_{j,k})^2}$;

Miary odległości obiektów (2)

Odległości $D(X_i, X_j)$ mogą być różnie definiowane. Jeżeli obiekty są opisane za pomocą atrybutów mierzalnych (ilościowych), ale nie binarnych, np. za pomocą p atrybutów, czyli w postaci $X_i = (X_{i,1}, \dots, X_{i,p})$, $X_j = (X_{j,1}, \dots, X_{j,p})$, wówczas stosuje się następujące miary:

- **odległość euklidesowa:** $D(X_i, X_j) = \sqrt{\sum_{k=1}^p (X_{i,k} - X_{j,k})^2}$;
- **kwadrat odległości euklidesowej:** jest wybierany jako miara odległości wówczas, gdy obiektom bardziej oddalonym od siebie chcemy przypisać większą wagę;

Miary odległości obiektów (2)

Odległości $D(X_i, X_j)$ mogą być różnie definiowane. Jeżeli obiekty są opisane za pomocą atrybutów mierzalnych (ilościowych), ale nie binarnych, np. za pomocą p atrybutów, czyli w postaci $X_i = (X_{i,1}, \dots, X_{i,p})$, $X_j = (X_{j,1}, \dots, X_{j,p})$, wówczas stosuje się następujące miary:

- **odległość euklidesowa:** $D(X_i, X_j) = \sqrt{\sum_{k=1}^p (X_{i,k} - X_{j,k})^2}$;
- **kwadrat odległości euklidesowej:** jest wybierany jako miara odległości wówczas, gdy obiektom bardziej oddalonym od siebie chcemy przypisać większą wagę;
- **odległość Czebyszewa:** $D(X_i, X_j) = \max_{1 \leq k \leq p} |X_{i,k} - X_{j,k}|$;

- **odległość miejska (Manhattan):**

$$D(X_i, X_j) = \sum_{k=1}^p |X_{i,k} - X_{j,k}|;$$

Copyright by Wojciech Kempa

- **odległość miejska (Manhattan):**

$$D(X_i, X_j) = \sum_{k=1}^p |X_{i,k} - X_{j,k}|;$$

- **odległość Minkowskiego:**

$$D(X_i, X_j) = \left(\sum_{k=1}^p |X_{i,k} - X_{j,k}|^{\hat{p}} \right)^{1/\hat{p}}, \text{ gdzie } \hat{p} \geq 1;$$

Copyright by Wojciech Kempa

Miary odległości obiektów (3)

- **odległość miejska (Manhattan):**

$$D(X_i, X_j) = \sum_{k=1}^p |X_{i,k} - X_{j,k}|;$$

- **odległość Minkowskiego:**

$$D(X_i, X_j) = \left(\sum_{k=1}^p |X_{i,k} - X_{j,k}|^{\hat{p}} \right)^{1/\hat{p}}, \text{ gdzie } \hat{p} \geq 1;$$

- **odległość Mahalanobisa:** definiowana jako

$$D(X_i, X_j) = \sqrt{\sum_{k=1}^p \sum_{l=1}^p (X_{i,k} - X_{j,k})(X_{i,l} - X_{j,l})s_{i,j}},$$

gdzie $s_{i,j}$ jest kowariancją obiektu X_i oraz X_j (traktujemy je jak wektory).

- Zauważmy, że odległość euklidesowa oraz odległość miejska są szczególnymi przypadkami odległości Minkowskiego (odpowiednio, $\hat{p} = 2$ oraz $\hat{p} = 1$).

Copyright by Wojciech Kempa

Miary odległości obiektów (4)

- Zauważmy, że odległość euklidesowa oraz odległość miejska są szczególnymi przypadkami odległości Minkowskiego (odpowiednio, $\hat{p} = 2$ oraz $\hat{p} = 1$).
- Odległość Mahalanobisa stosuje się w sytuacji dużego skorelowania obiektów X_i i X_j (traktowanych jako wektory współrzędnych).

Miary odległości obiektów (4)

- Zauważmy, że odległość euklidesowa oraz odległość miejska są szczególnymi przypadkami odległości Minkowskiego (odpowiednio, $\hat{p} = 2$ oraz $\hat{p} = 1$).
- Odległość Mahalanobisa stosuje się w sytuacji dużego skorelowania obiektów X_i i X_j (traktowanych jako wektory współrzędnych).
- W takiej sytuacji metryka euklidesowa może dawać wyniki mylące.

- W przypadku dużych różnic pomiędzy wartościami poszczególnych atrybutów dla różnych obiektów, powstaje **problem skalowalności** (np. obiekty (1, 23) oraz (1, 5023)).

Copyright by Wojciech Kempa

Miary odległości obiektów (5)

- W przypadku dużych różnic pomiędzy wartościami poszczególnych atrybutów dla różnych obiektów, powstaje **problem skalowalności** (np. obiekty (1, 23) oraz (1, 5023)).
- Stosuje się wówczas **standaryzację** zmiennych (odejmujemy od wartości atrybutów ich średnią arytmetyczną i dzielimy przez odchylenie standardowe).

Miary odległości obiektów (5)

- W przypadku dużych różnic pomiędzy wartościami poszczególnych atrybutów dla różnych obiektów, powstaje **problem skalowalności** (np. obiekty (1, 23) oraz (1, 5023)).
- Stosuje się wówczas **standaryzację** zmiennych (odejmujemy od wartości atrybutów ich średnią arytmetyczną i dzielimy przez odchylenie standardowe).
- Czasem stosuje się także tzw. **unitaryzację**. Przyjmujemy wówczas nowe wartości atrybutu w próbie, dzieląc wartości dotychczasowe przez ich rozstęp (różnicę pomiędzy wartością maksymalną a minimalną).

Miary odległości obiektów (6)

W przypadku **atrybutów binarnych** (przyjmujących wyłącznie wartości 0 lub 1) stosuje się następującą miarę odległości:

$$D(X_i, X_j) = \frac{\text{liczba atrybutów o różnych wartościach w obiektach } X_i \text{ i } X_j}{\text{liczba wszystkich atrybutów}}.$$

Powyższą miarę odległości stosuje się w przypadku atrybutów binarnych, które mają w populacji podobne wagi (np. płeć). Atrybuty takie nazywamy **symetrycznymi**.

Miary odległości obiektów (7)

W przypadku, gdy wagi są różne (**atrybuty asymetryczne**), stosuje się modyfikację powyższej miary, zdefiniowaną w następujący sposób:

$$D(X_i, X_j) \text{ Copyright by Wojciech Kempa} \\ = \frac{\text{liczba atrybutów o różnych wartościach w obiektach } X_i \text{ i } X_j}{\text{liczba atrybutów, które w choć jednym z obiektów mają wartość 1}}.$$

Miary odległości obiektów (8)

W sytuacji, gdy atrybuty dane są w skali nominalnej lub porządkowej, sposób postępowania opisano poniżej.

- Dla atrybutów danych w skali nominalnej stosuje się miarę postaci

$$D(X_i, X_j) = \frac{\text{liczba atrybutów o różnych kategoriach}}{\text{liczba wszystkich atrybutów}}.$$

Miary odległości obiektów (8)

W sytuacji, gdy atrybuty dane są w skali nominalnej lub porządkowej, sposób postępowania opisano poniżej.

- Dla atrybutów danych w skali nominalnej stosuje się miarę postaci

$$D(X_i, X_j) = \frac{\text{liczba atrybutów o różnych kategoriach}}{\text{liczba wszystkich atrybutów}}.$$

- Dla atrybutów danych w skali porządkowej przyporządkowuje się im wartości równe $\frac{i-1}{M-1}$, gdzie $i = 1, \dots, M$, przy czym M oznacza liczbę różnych kategorii danego atrybutu. Następnie stosuje się jedną ze zwykłych miar stosowanych w przypadku atrybutów o charakterze ilościowym.

Zagregowana miara niepodobieństwa (1)

- Jeżeli atrybuty obiektów należą do różnych typów, wówczas do oceny odległości tych obiektów stosuje się tzw. **zagregowaną miarę niepodobieństwa (odległości)**, zdefiniowaną jako

$$D(X_i, X_j) = \sum_{k=1}^p w_k d_k(X_i, X_j), \quad \sum_{k=1}^p w_k = 1,$$

gdzie p jest liczbą atrybutów, za pomocą których opisywane są obiekty, $d_k(X_i, X_j)$ jest odległością k -tego atrybutu dla obiektów X_i i X_j , natomiast w_k jest **wagą** k -tego atrybutu.

Zagregowana miara niepodobieństwa (1)

- Jeżeli atrybuty obiektów należą do różnych typów, wówczas do oceny odległości tych obiektów stosuje się tzw. **zagregowaną miarę niepodobieństwa (odległości)**, zdefiniowaną jako

$$D(X_i, X_j) = \sum_{k=1}^p w_k d_k(X_i, X_j), \quad \sum_{k=1}^p w_k = 1,$$

gdzie p jest liczbą atrybutów, za pomocą których opisywane są obiekty, $d_k(X_i, X_j)$ jest odległością k -tego atrybutu dla obiektów X_i i X_j , natomiast w_k jest **wagą** k -tego atrybutu.

- Dodatkowo definiuje się także **średnią wartość niepodobieństwa obiektów** z całej badanej zbiorowości (lub próby) n -elementowej jako

$$\overline{D} = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n D(X_i, X_j).$$

Zagregowana miara niepodobieństwa (2)

- Wielkość \overline{D} można wyrazić także w następujący sposób:

$$\overline{D} = \sum_{k=1}^p w_k \overline{d}_k,$$

gdzie $\overline{d}_k = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n d_k(X_i, X_j).$

Copyright by Wojciech Kempa

Zagregowana miara niepodobieństwa (2)

- Wielkość \overline{D} można wyrazić także w następujący sposób:

$$\overline{D} = \sum_{k=1}^p w_k \overline{d}_k,$$

gdzie $\overline{d}_k = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n d_k(X_i, X_j)$.

- Względny wpływ k -tego atrybutu na średnią wartość niepodobieństwa** wszystkich par obiektów z badanej grupy wynosi $w_k \overline{d}_k$.

Zagregowana miara niepodobieństwa (2)

- Wielkość \overline{D} można wyrazić także w następujący sposób:

$$\overline{D} = \sum_{k=1}^p w_k \overline{d}_k,$$

gdzie $\overline{d}_k = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n d_k(X_i, X_j)$.

- Względny wpływ k -tego atrybutu na średnią wartość niepodobieństwa** wszystkich par obiektów z badanej grupy wynosi $w_k \overline{d}_k$.
- Jeżeli chcemy, by wszystkie atrybuty miały podobny wpływ na średnią wartość niepodobieństwa, należy przyjąć w_k proporcjonalne do wartości $\frac{1}{\overline{d}_k}$ i do procentowego udziału atrybutu w wartości zagregowanej miary niepodobieństwa.