

Algorytmy eksploracji danych: Wykład 7

Wojciech Kempa

Politechnika Śląska
Wydział Matematyki Stosowanej

- Załóżmy, że dysponujemy pewnym zbiorem obiektów opisanych za pomocą wielu atrybutów, którego elementy zostały przyporządkowane do pewnej liczby klas.

light by Wojciech Kempa

Wprowadzenie do klasyfikacji

- Załóżmy, że dysponujemy pewnym zbiorem obiektów opisanych za pomocą wielu atrybutów, którego elementy zostały przyporządkowane do pewnej liczby klas.
- Do której z tych klas należy przyporządkować nowy obiekt opisany za pomocą tych samych atrybutów?

light by Wojciech Kempa

Wprowadzenie do klasyfikacji

- Załóżmy, że dysponujemy pewnym zbiorem obiektów opisanych za pomocą wielu atrybutów, którego elementy zostały przyporządkowane do pewnej liczby klas.
- Do której z tych klas należy przyporządkować nowy obiekt opisany za pomocą tych samych atrybutów?
- Jak sprawdzić, czy stworzona w ten sposób reguła klasyfikacyjna jest dokładna i sprawdzi się w przyszłości w przypadku większej liczby obiektów?

Wprowadzenie do klasyfikacji

- Załóżmy, że dysponujemy pewnym zbiorem obiektów opisanych za pomocą wielu atrybutów, którego elementy zostały przyporządkowane do pewnej liczby klas.
- Do której z tych klas należy przyporządkować nowy obiekt opisany za pomocą tych samych atrybutów?
- Jak sprawdzić, czy stworzona w ten sposób reguła klasyfikacyjna jest dokładna i sprawdzi się w przyszłości w przypadku większej liczby obiektów?
- Odpowiedzi na te i podobne pytania są domeną jednej z dziedzin eksploracji danych zwanej **klasyfikacją**.

Wprowadzenie do klasyfikacji

- Załóżmy, że dysponujemy pewnym zbiorem obiektów opisanych za pomocą wielu atrybutów, którego elementy zostały przyporządkowane do pewnej liczby klas.
- Do której z tych klas należy przyporządkować nowy obiekt opisany za pomocą tych samych atrybutów?
- Jak sprawdzić, czy stworzona w ten sposób reguła klasyfikacyjna jest dokładna i sprawdzi się w przyszłości w przypadku większej liczby obiektów?
- Odpowiedzi na te i podobne pytania są domeną jednej z dziedzin eksploracji danych zwanej **klasyfikacją**.
- Zasadniczym celem jest tu zbudowanie ogólnego modelu klasyfikacyjnego zbioru obiektów na podstawie danych historycznych, a następnie zastosowanie go do predykcji klasy nowego obiektu.

- Dane wejściowe stanowi pewien zbiór obiektów (obserwacji itp.) D zwany **zbiorem treningowym**, którego elementy (obiekty) opisane są za pomocą pewnej skończonej liczby tzw. **atrybutów warunkowych** A_1, A_2, \dots, A_s i jednego tzw. **atrybutu decyzyjnego** C określającego przyporządkowanie obiektu do danej klasy.

Wojciech Kempa

- Dane wejściowe stanowi pewien zbiór obiektów (obserwacji itp.) D zwany **zbiorem treningowym**, którego elementy (obiekty) opisane są za pomocą pewnej skończonej liczby tzw. **atrybutów warunkowych** A_1, A_2, \dots, A_s i jednego tzw. **atrybutu decyzyjnego** C określającego przyporządkowanie obiektu do danej klasy.
- Atrybut decyzyjny jest atrybutem kategoriowym, jego wartości C_1, \dots, C_m , $m \geq 2$, to tzw. **klasy decyzyjne**.

- Dane wejściowe stanowi pewien zbiór obiektów (obserwacji itp.) D zwany **zbiorem treningowym**, którego elementy (obiekty) opisane są za pomocą pewnej skończonej liczby tzw. **atrybutów warunkowych** A_1, A_2, \dots, A_s i jednego tzw. **atrybutu decyzyjnego** C określającego przyporządkowanie obiektu do danej klasy.
- Atrybut decyzyjny jest atrybutem kategoriowym, jego wartości C_1, \dots, C_m , $m \geq 2$, to tzw. **klasy decyzyjne**.
- Atrybuty warunkowe mogą być atrybutami ilościowymi, binarnymi lub też jakościowymi, określonymi za pomocą skali porządkowej lub nominalnej.

- Celem procesu klasyfikacji jest znalezienie **funkcji klasyfikującej (klasyfikatora)**, która pozwoli na jednoznaczne przyporządkowanie nowego obiektu $X = (A_1 = x_1, \dots, A_s = x_s)$ do jednej z m klas decyzyjnych C_1, \dots, C_m . **light by Wojciech Kempa**

- Celem procesu klasyfikacji jest znalezienie **funkcji klasyfikującej (klasyfikatora)**, która pozwoli na jednoznaczne przyporządkowanie nowego obiektu $X = (A_1 = x_1, \dots, A_s = x_s)$ do jednej z m klas decyzyjnych C_1, \dots, C_m . **light by Wojciech Kempa**
- Konstrukcja klasyfikatora odbywa się z istotnym wykorzystaniem zbioru treningowego, czyli zbioru obiektów, które **już są przyporządkowane do odpowiednich klas decyzyjnych**.

Przykład 1 (1)

Jako przykład rozważmy zbiór treningowy D opisujący klientów pewnego banku (mężczyzn), w którym atrybutami warunkowymi są

- A_1 : *Wiek* – atrybut ilościowy ciągły;
- A_2 : *Status* – atrybut jakościowy dany w skali nominalnej (Kawaler, Żonaty, Rozwiedziony);
- A_3 : *Dochód* – atrybut jakościowy dany w skali porządkowej (Niski, Średni, Wysoki);
- A_4 : *Liczba dzieci* – atrybut ilościowy dyskretny.

Atrybut decyzyjny C jest związany z pozytywnym bądź negatywnym zaopiniowaniem wniosku kredytowego klienta. Wyróżniamy w nim dwie klasy związane z poziomem ryzyka:

- C_1 : Wysokie;
- C_2 : Niskie.

Przykład 1 (2)

Baza danych D może mieć następującą postać:

$L.p.$	$Wiek (A_1)$	$Status (A_2)$	$Dochód (A_3)$	$Dzieci (A_4)$	$Ryzyko (C)$
1	26	Kawaler	Niski	0	Wysokie
2	35	Żonaty	Średni	1	Niskie
3	36	Żonaty	Wysoki	2	Niskie
4	49	Rozwiedziony	Średni	2	Niskie
5	27	Żonaty	Niski	1	Wysokie
6	39	Rozwiedziony	Wysoki	0	Wysokie
7	31	Żonaty	Niski	2	Wysokie
8	50	Żonaty	Wysoki	2	Niskie
9	51	Kawaler	Średni	1	Niskie
10	38	Rozwiedziony	Niski	2	Wysokie
11	29	Kawaler	Wysoki	0	Niskie
12	42	Rozwiedziony	Średni	4	Wysokie
13	41	Żonaty	Średni	1	Niskie
14	56	Rozwiedziony	Wysoki	2	Niskie
15	32	Kawaler	Średni	0	Niskie
16	45	Żonaty	Średni	4	Wysokie

Tablica 1: Przykładowy zbiór treningowy D (źródło: T. Morzy
Eksploracja danych)

Konstrukcja modelu klasyfikacyjnego (1)

Tak naprawdę, w praktyce, na początku procesu klasyfikacyjnego z reguły całą dostępną bazę danych dzielimy na zbiór treningowy, na podstawie którego konstruowany będzie klasyfikator, oraz **zbiór testowy**, który posłuży do weryfikacji jakości zbudowanego klasyfikatora. Konstrukcja modelu klasyfikacyjnego przebiega zatem dwuetapowo, obejmując następujące dwa kroki:

- **krok uczenia (treningu)**, w którym z wykorzystaniem zbioru treningowego konstruowany jest odpowiedni klasyfikator (za pomocą tzw. **algorytmu uczącego**);
- **krok testowania**, w którym weryfikowana jest jakość zbudowanego modelu na podstawie bazy danych stanowiących zbiór testowy.

Konstrukcja modelu klasyfikacyjnego (2)

W praktyce istnieje wiele różnych metod (algorytmów uczących) konstruowania klasyfikatorów. Najważniejsze z nich to m.in.

- drzewa klasyfikacyjne (decyzyjne);
- klasyfikatory bayesowskie;
- reguły klasyfikacyjne typu “if–then–else”;
- sztuczne sieci neuronowe.

Wśród metod wykorzystywanych w klasyfikacji wyróżnia się też takie, w których klasyfikacja przebiega „na bieżąco”, tzn. bez konstruowania modelu klasyfikacyjnego. Najważniejszą z takich metod jest **metoda k najbliższych „sąsiadów”** oznaczana w skrócie jako **metoda k -NN** (ang. *k-Nearest Neighbors*).

Drzewa decyzyjne (1)

- Indukcja tzw. **drzewa decyzyjnego** to jedna z najważniejszych technik stosowanych w klasyfikacji.

light by Wojciech Kempa

Drzewa decyzyjne (1)

- Indukcja tzw. **drzewa decyzyjnego** to jedna z najważniejszych technik stosowanych w klasyfikacji.
- Znajduje ona bardzo wiele zastosowań w naukach technicznych (np. w modelowaniu ryzyka awarii i systemach zabezpieczeń), ekonomicznych (np. w modelowaniu ryzyka inwestycyjnego, ubezpieczeniowego), ale także w naukach przyrodniczych i medycznych (np. w konstrukcji tzw. szybkiej ścieżki diagnostycznej dla konkretnego schorzenia).

Drzewa decyzyjne (1)

- Indukcja tzw. **drzewa decyzyjnego** to jedna z najważniejszych technik stosowanych w klasyfikacji.
- Znajduje ona bardzo wiele zastosowań w naukach technicznych (np. w modelowaniu ryzyka awarii i systemach zabezpieczeń), ekonomicznych (np. w modelowaniu ryzyka inwestycyjnego, ubezpieczeniowego), ale także w naukach przyrodniczych i medycznych (np. w konstrukcji tzw. szybkiej ścieżki diagnostycznej dla konkretnego schorzenia).
- **Drzewo decyzyjne** to graf bez cykli (pętli), w którym istnieje tylko jedna ścieżka między dwoma różnymi węzłami.

Drzewa decyzyjne (1)

- Indukcja tzw. **drzewa decyzyjnego** to jedna z najważniejszych technik stosowanych w klasyfikacji.
- Znajduje ona bardzo wiele zastosowań w naukach technicznych (np. w modelowaniu ryzyka awarii i systemach zabezpieczeń), ekonomicznych (np. w modelowaniu ryzyka inwestycyjnego, ubezpieczeniowego), ale także w naukach przyrodniczych i medycznych (np. w konstrukcji tzw. szybkiej ścieżki diagnostycznej dla konkretnego schorzenia).
- **Drzewo decyzyjne** to graf bez cykli (pętli), w którym istnieje tylko jedna ścieżka między dwoma różnymi węzłami.
- Reprezentuje ono pewien proces danego podziału zbioru obiektów na rozłączne klasy względem atrybutu decyzyjnego.

Drzewa decyzyjne (1)

- Indukcja tzw. **drzewa decyzyjnego** to jedna z najważniejszych technik stosowanych w klasyfikacji.
- Znajduje ona bardzo wiele zastosowań w naukach technicznych (np. w modelowaniu ryzyka awarii i systemach zabezpieczeń), ekonomicznych (np. w modelowaniu ryzyka inwestycyjnego, ubezpieczeniowego), ale także w naukach przyrodniczych i medycznych (np. w konstrukcji tzw. szybkiej ścieżki diagnostycznej dla konkretnego schorzenia).
- **Drzewo decyzyjne** to graf bez cykli (pętli), w którym istnieje tylko jedna ścieżka między dwoma różnymi węzłami.
- Reprezentuje ono pewien proces danego podziału zbioru obiektów na rozłączne klasy względem atrybutu decyzyjnego.
- Tworzenie drzewa rozpoczynamy od jego **korzenia (wierzchołka)**, z którego wychodzą **krawędzie (gałęzie)** reprezentujące wartości cech, na podstawie których dokonujemy podziału zbioru obiektów.

Drzewa decyzyjne (2)

- Wewnętrzne węzły drzewa opisują sposób dokonania tego podziału. Zakończenia krawędzi czyli **liście** drzewa odpowiadają klasom, do których należą obiekty.

right by Wojciech Kempa

Drzewa decyzyjne (2)

- Wewnętrzne węzły drzewa opisują sposób dokonania tego podziału. Zakończenia krawędzi czyli **liście** drzewa odpowiadają klasom, do których należą obiekty.
- Pierwsze algorytmy indukowania drzew klasyfikacyjnych pojawiły się w latach 70. dwudziestego wieku.

light by Wojciech Kempa

Drzewa decyzyjne (2)

- Wewnętrzne węzły drzewa opisują sposób dokonania tego podziału. Zakończenia krawędzi czyli **liście** drzewa odpowiadają klasom, do których należą obiekty.
- Pierwsze algorytmy indukowania drzew klasyfikacyjnych pojawiły się w latach 70. dwudziestego wieku.
- Jedne z pierwszych to **algorytm CHAID** (ang. *Chi-squared Automatic Interaction Detection*), oryginalnie zaproponowany tylko dla atrybutów danych w skali nominalnej, oraz **algorytm Id3** (Quinlan, 1986).

Drzewa decyzyjne (2)

- Wewnętrzne węzły drzewa opisują sposób dokonania tego podziału. Zakończenia krawędzi czyli **liście** drzewa odpowiadają klasom, do których należą obiekty.
- Pierwsze algorytmy indukowania drzew klasyfikacyjnych pojawiły się w latach 70. dwudziestego wieku.
- Jedne z pierwszych to **algorytm CHAID** (ang. *Chi-squared Automatic Interaction Detection*), oryginalnie zaproponowany tylko dla atrybutów danych w skali nominalnej, oraz **algorytm Id3** (Quinlan, 1986).
- Modyfikacja algorytmu Id3, czyli **algorytm C4.5** (Quinlan, 1993), oraz zaproponowany przez Breimana w 1984 roku **algorytm CART** stanowią swoistą bazę, na podstawie której w późniejszych latach powstało bardzo wiele innych algorytmów, m.in. **algorytm SPRINT**, wykorzystywany w komercyjnym systemie IBM Intelligent Miner.

Algorytmy wyboru atrybutu „podziałowego”

Absolutnie kluczową kwestią w przypadku konstrukcji drzewa decyzyjnego jest określenie **sposobu wyboru atrybutu „podziałowego”** na każdym etapie konstrukcji drzewa, a zatem atrybutu, który będzie generował podział drzewa na gałęzie: początkowo w korzeniu drzewa, a później na etapie węzłów pośrednich. W praktyce stosuje się w tym celu trzy różne podejścia, a co za tym idzie różne miary ilościowe:

- entropię (np. algorytmy Id3, C4.5);
- tzw. indeks Gini (Ginięgo) (np. algorytmy CART, SPRINT);
- statystykę χ^2 (np. algorytm CHAID).

Ogólny schemat konstrukcji drzewa decyzyjnego (1)

Zanim omówimy w szczegółach i na przykładach wymienione miary, przedstawmy ogólny schemat konstrukcji drzewa decyzyjnego.

Obejmuje on następujące etapy.

1. Tworzymy korzeń drzewa reprezentujący dany zbiór treningowy D . Jeżeli wszystkie obiekty zbioru D reprezentują jedną i tę samą klasę C_i atrybutu decyzyjnego C , to przypisujemy mu etykietę C_i (korzeń staje się liściem drzewa) i procedura się kończy.
2. Jeżeli obiekty zbioru D reprezentują różne klasy atrybutu decyzyjnego, analizowany jest zbiór atrybutów warunkowych A_i , spośród których wybierany jest atrybut „podziałowy”. Jeśli zbiór atrybutów warunkowych jest pusty, korzeniowi przyporządkowujemy etykietę klasy C_i dominującej w zbiorze D i procedura się kończy (korzeń staje się liściem drzewa).

Ogólny schemat konstrukcji drzewa decyzyjnego (2)

3. Po przeprowadzeniu podziału w korzeniu drzewa analizujemy zbiór atrybutów warunkowych w każdym z nowo powstałych węzłów (oczywiście nie bierzemy już pod uwagę atrybutu, który był atrybutem „podziałowym” w pierwszym etapie). Jeśli zbiór atrybutów jest pusty, to bieżący węzeł staje się liściem drzewa z etykietą klasy dominującej. Jeśli zbiór atrybutów jest niepusty, dokonujemy kolejnego wyboru atrybutu „podziałowego” itd.
4. Podczas podziału w węźle drzewa dla każdej wartości (kategorii) atrybutu „podziałowego” tworzona jest krawędź (gałąź) drzewa o etykiecie odpowiadającej tej wartości. Gałąź kończy się nowym węzłem drzewa.

Algorytm oparty na entropii (1)

Jeżeli X jest zmienną losową typu dyskretnego, przyjmującą wartości x_1, \dots, x_m z prawdopodobieństwami, odpowiednio, p_1, \dots, p_m , wówczas **entropię** zmiennej X definiujemy w następujący sposób:

$$H(X) \stackrel{\text{def}}{=} - \sum_{i=1}^m p_i \log_2 p_i.$$

Entropia jest miarą nieuporządkowania, rozproszenia zbioru danych. Rzeczywiście, przy równomiernym rozkładzie prawdopodobieństwa (maksymalnym rozproszeniu), tzn. gdy $p_i = \frac{1}{m}$, jej wartość jest maksymalna i wynosi $\log_2 m$.

- W teorii informacji entropia wyraża średnią ważoną ilość informacji dostarczanej przez pojedynczą wiadomość generowaną przez źródło informacji, przy czym wagami są tu prawdopodobieństwa nadania (wygenerowania) poszczególnych wiadomości.
- light by Wojciech Kempa

Algorytm oparty na entropii (2)

- W teorii informacji entropia wyraża średnią ważoną ilości informacji dostarczanej przez pojedynczą wiadomość generowaną przez źródło informacji, przy czym wagami są tu prawdopodobieństwa nadania (wygenerowania) poszczególnych wiadomości. **light by Wojciech Kempa**
- W praktyce można spotkać się z definicją entropii, w której logarytmy obliczane są przy podstawie innej niż 2. Jeżeli podstawa logarytmu wynosi 2, wówczas jednostką entropii jest **bit**.

Algorytm oparty na entropii (3)

Zastosowanie pojęcia entropii w procedurze indukowania drzewa decyzyjnego przebiega w następujący sposób. Podzielmy cały n -elementowy zbiór treningowy D na m rozłącznych **partycji** D_1, \dots, D_m związanych z wartościami (kategoriami) atrybutu decyzyjnego C . Oznaczmy przez n_i liczbę elementów partycji D_i , $i = 1, \dots, m$. Entropia zbioru treningowego jest wówczas równa

light by Wojciech Kempa

$$H(D) = - \sum_{i=1}^m p_i \log_2 p_i = - \sum_{i=1}^m \frac{n_i}{n} \log_2 \frac{n_i}{n},$$

ponieważ prawdopodobieństwa p_i estymujemy za pomocą częstości empirycznych $\frac{n_i}{n}$. Jeżeli któraś z kategorii atrybutu decyzyjnego nie występuje w zbiorze treningowym (odpowiednie $n_i = 0$), wówczas przyjmujemy $\log_2 p_i = 0$.

Założmy, że atrybut warunkowy A przyjmuje r różnych wartości (występuje w r różnych kategoriach) a_1, \dots, a_r i niech $n_{i,j}$ oznacza liczbę elementów partycji D_i , w których $A = a_j$, $i = 1, \dots, m$, $j = 1, \dots, r$. **Entropię kategorii a_j atrybutu A w zbiorze treningowym** możemy zdefiniować w następujący sposób:

ight by Wojciech Kempa

$$H(a_j) = - \sum_{i=1}^m p_{i,j} \log_2 p_{i,j} = - \sum_{i=1}^m \frac{n_{i,j}}{n_j} \log_2 \frac{n_{i,j}}{n_j},$$

gdzie $n_{i,j}$ oznacza liczbę obiektów zbioru treningowego należących do partycji D_i , dla których równocześnie $A = a_j$.

Entropię atrybutu A definiujemy jako następującą ważoną sumę:

$$H(A) = \sum_{j=1}^r \hat{n}_j H(a_j) = \frac{1}{n} \sum_{j=1}^r (n_{1,j} + \dots + n_{m,j}) H(a_j).$$

Iloraz $\hat{n}_j = \frac{n_{1,j} + \dots + n_{m,j}}{n}$ jest częstością względną wystąpienia kategorii a_j w zbiorze treningowym D .

Mając zdefiniowaną entropię atrybutu A , definiujemy teraz tzw. **zysk informacyjny dla atrybutu A** w następujący sposób:

$$Gain(A) = H(D) - H(A).$$

Zysk informacyjny wyraża różnicę pomiędzy ilością informacji niezbędnej do sklasyfikowania dowolnego obiektu ze zbioru D przed podziałem tego zbioru oraz po jego podziale z wykorzystaniem atrybutu A jako atrybutu „podziałowego”.

W praktyce na każdym etapie konstrukcji drzewa klasyfikacyjnego obliczamy zysk informacyjny dla każdego z dostępnych jeszcze atrybutów warunkowych. **Wybieramy jako atrybut „podziałowy” ten, dla którego zysk informacyjny jest największy (czyli, równoważnie, entropia jest minimalna).**