

Algorytmy eksploracji danych: Wykład 12

Copyright by Wojciech Kempa

Politechnika Śląska
Wydział Matematyki Stosowanej

Algorytm Max-Miner (1)

- **Algorytm Max-Miner** jest algorytmem zaproponowanym w 1998 roku przez R. J. Bayardo do znajdowania maksymalnych zbiorów częstych.

Copyright by Wojciech Kempa

Algorytm Max-Miner (1)

- **Algorytm Max-Miner** jest algorytmem zaproponowanym w 1998 roku przez R. J. Bayardo do znajdowania maksymalnych zbiorów częstych.
- Algorytm ten próbuje „wybiegać w przyszłość”, by szybko zidentyfikować zbiory częste o dużej liczności.

Copyright by Wojciech Kempa

- **Algorytm Max-Miner** jest algorytmem zaproponowanym w 1998 roku przez R. J. Bayardo do znajdowania maksymalnych zbiorów częstych.
- Algorytm ten próbuje „wybiegać w przyszłość”, by szybko zidentyfikować zbiory częste o dużej liczności.
- Dzięki wczesnej identyfikacji tego typu zbiorów można usunąć wszystkie ich podzbiory z rozważanej bazy danych (będą one zbiorami częstymi), by zredukować jej rozmiar.

- **Algorytm Max-Miner** jest algorytmem zaproponowanym w 1998 roku przez R. J. Bayardo do znajdowania maksymalnych zbiorów częstych.
- Algorytm ten próbuje „wybiegać w przyszłość”, by szybko zidentyfikować zbiory częste o dużej liczności.
- Dzięki wczesnej identyfikacji tego typu zbiorów można usunąć wszystkie ich podzbiory z rozważanej bazy danych (będą one zbiorami częstymi), by zredukować jej rozmiar.
- Algorytm Max-Miner wykorzystuje zarówno przycinanie podzbiorów jak i nadzbiorów. Dodatkowo używa się w nim również drzewa enumeracji zbiorów (SE-drzewa).

Algorytm Max-Miner (2)

- Każdy węzeł drzewa enumeracji zbiorów nazywamy **grupą kandydującą** (oznaczamy ją literą g).

Copyright by Wojciech Kempa

Algorytm Max-Miner (2)

- Każdy węzeł drzewa enumeracji zbiorów nazywamy **grupą kandydującą** (oznaczamy ją literą g).
- Z grupą kandydującą g związane są dwa zbiory. Pierwszy z nich nazywamy **głową** i oznaczamy przez $h(g)$. Głowa reprezentuje zbiór odpowiadający danemu wierzchołkowi.

Copyright by Wojciech Kempa

- Każdy węzeł drzewa enumeracji zbiorów nazywamy **grupą kandydującą** (oznaczamy ją literą g).
- Z grupą kandydującą g związane są dwa zbiory. Pierwszy z nich nazywamy **głową** i oznaczamy przez $h(g)$. Głowa reprezentuje zbiór odpowiadający danemu wierzchołkowi.
- Drugi ze zbiorów nazywamy **ogonem** i oznaczamy przez $t(g)$. Zbiór $t(g)$ zawiera elementy, które nie znajdują się w zbiorze $h(g)$, ale które mogą pojawić się w każdym kolejnym podwęźle węzła g .

Algorytm Max-Miner (2)

- Każdy węzeł drzewa enumeracji zbiorów nazywamy **grupą kandydującą** (oznaczamy ją literą g).
- Z grupą kandydującą g związane są dwa zbiory. Pierwszy z nich nazywamy **głową** i oznaczamy przez $h(g)$. Głowa reprezentuje zbiór odpowiadający danemu wierzchołkowi.
- Drugi ze zbiorów nazywamy **ogonem** i oznaczamy przez $t(g)$. Zbiór $t(g)$ zawiera elementy, które nie znajdują się w zbiorze $h(g)$, ale które mogą pojawić się w każdym kolejnym podwęźle węzła g .
- Aby wyznaczyć wartość miary wsparcia grupy kandydującej g , obliczamy wsparcie zbiorów $h(g)$, $h(g) \cup t(g)$ oraz $h(g) \cup \{i\}$ dla każdego $i \in t(g)$.

- Każdy węzeł drzewa enumeracji zbiorów nazywamy **grupą kandydującą** (oznaczamy ją literą g).
- Z grupą kandydującą g związane są dwa zbiory. Pierwszy z nich nazywamy **głową** i oznaczamy przez $h(g)$. Głowa reprezentuje zbiór odpowiadający danemu wierzchołkowi.
- Drugi ze zbiorów nazywamy **ogonem** i oznaczamy przez $t(g)$. Zbiór $t(g)$ zawiera elementy, które nie znajdują się w zbiorze $h(g)$, ale które mogą pojawić się w każdym kolejnym podwęźle węzła g .
- Aby wyznaczyć wartość miary wsparcia grupy kandydującej g , obliczamy wsparcie zbiorów $h(g)$, $h(g) \cup t(g)$ oraz $h(g) \cup \{i\}$ dla każdego $i \in t(g)$.
- Wartości miar wsparcia zbiorów $h(g) \cup t(g)$ oraz $h(g) \cup \{i\}$ wykorzystujemy w procesie przycinania drzewa.

Algorytm Max-Miner (3)

- Zbiór $h(g) \cup t(g)$ zawiera każdy element, który znajduje się w dowolnym podwęźle węzła g .

Copyright by Wojciech Kempa

Algorytm Max-Miner (3)

- Zbiór $h(g) \cup t(g)$ zawiera każdy element, który znajduje się w dowolnym podwęźle węzła g .
- W konsekwencji, jeśli g jest zbiorem częstym, to każdy zbiór częsty znaleziony w podwęźle węzła g nie będzie maksymalnym zbiorem częstym.

Copyright by Wojciech Kempa

Algorytm Max-Miner (3)

- Zbiór $h(g) \cup t(g)$ zawiera każdy element, który znajduje się w dowolnym podwęźle węzła g .
- W konsekwencji, jeśli g jest zbiorem częstym, to każdy zbiór częsty znaleziony w podwęźle węzła g nie będzie maksymalnym zbiorem częstym.
- Przycinanie wykorzystujące nadzbiory można zaimplementować w algorytmie poprzez zatrzymanie rozwijania podwęzła w dowolnej grupie kandydującej g , dla której zbiór $h(g) \cup t(g)$ jest zbiorem częstym.

Algorytm Max-Miner (3)

- Zbiór $h(g) \cup t(g)$ zawiera każdy element, który znajduje się w dowolnym podwęźle węzła g .
- W konsekwencji, jeśli g jest zbiorem częstym, to każdy zbiór częsty znaleziony w podwęźle węzła g nie będzie maksymalnym zbiorem częstym.
- Przycinanie wykorzystujące nadzbiory można zaimplementować w algorytmie poprzez zatrzymanie rozwijania podwęzła w dowolnej grupie kandydującej g , dla której zbiór $h(g) \cup t(g)$ jest zbiorem częstym.
- Jeśli zbiór $h(g) \cup \{i\}$ nie jest zbiorem częstym, to również każda główna podwęzła, który zawiera element i nie będzie zbiorem częstym.

Algorytm Max-Miner (3)

- Zbiór $h(g) \cup t(g)$ zawiera każdy element, który znajduje się w dowolnym podwęźle węzła g .
- W konsekwencji, jeśli g jest zbiorem częstym, to każdy zbiór częsty znaleziony w podwęźle węzła g nie będzie maksymalnym zbiorem częstym.
- Przycinanie wykorzystujące nadzbiory można zaimplementować w algorytmie poprzez zatrzymanie rozwijania podwęzła w dowolnej grupie kandydującej g , dla której zbiór $h(g) \cup t(g)$ jest zbiorem częstym.
- Jeśli zbiór $h(g) \cup \{i\}$ nie jest zbiorem częstym, to również każda główna podwęzła, który zawiera element i nie będzie zbiorem częstym.
- Przycinanie podzbiorów polega zatem na usuwaniu dowolnego takiego elementu końcowego i z grupy kandydującej g przed rozwinięciem jej podwęzłów.

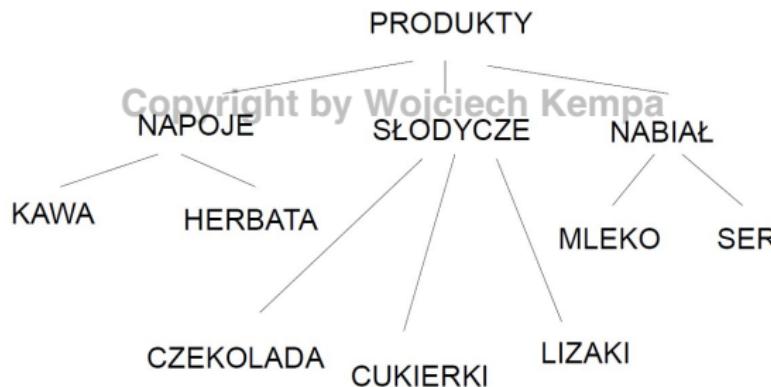
Algorytm Max-Miner ma następujący przebieg.

1. Najdujemy 1-elementowe zbiory częste w bazie danych D . Zbiory te generują pierwsze grupy kandydujące.
2. Dla ustalonego węzła (grupy kandydującej) g obliczamy wsparcie zbioru $h(g) \cup t(g)$.
3. Jeżeli $supp(h(g) \cup t(g)) \geq min\ supp$, to nie rozwijamy drzewa z węzła g . Zbiór $h(g) \cup t(g)$ jest maksymalnym zbiorem częstym.
4. Jeżeli $supp(h(g) \cup t(g)) < min\ supp$, to dla każdego $i \in t(g)$ sprawdzamy, czy zbiór $h(g) \cup \{i\}$ jest zbiorem częstym.

5. Jeżeli zbiór $h(g) \cup \{i\}$ nie jest zbiorem częstym, wówczas usuwamy element i z $t(g)$ i nie bierzemy go pod uwagę w tworzeniu kolejnych podwęzłów.
6. W przypadku gdy zbiór $h(g) \cup \{i\}$ jest zbiorem częstym, generujemy odpowiedni podwęzeł itd.
7. Powyższą procedurę przeprowadzamy dla każdego węzła (grupy kandydującej) utworzonego z 1-elementowego zbioru częstego bazy danych D .

Wielopoziomowe reguły asocjacyjne (1)

Proces odkrywania **wielopoziomowych reguł asocjacyjnych** wymaga zdefiniowania pojęcia taksonomii. **Taksonomia \mathcal{T}** jest rodzajem logicznego uporządkowania zbioru produktów z wyszczególnieniem poziomu ich abstrakcji. Przykładową taksonomię prezentuje Rysunek 3.



Rysunek: 3: Przykładowa taksonomia \mathcal{T}

Wielopoziomowe reguły asocjacyjne (2)

- Mówimy, że transakcja T **wspiera element** x , jeżeli $x \in T$ oraz x jest poprzednikiem dowolnego elementu $y \in T$ w taksonomii \mathcal{T} (w taksonomii zilustrowanej na Rysunku 3 np. poprzednikiem czekolady są słodycze, czyli element taksonomii o wyższym poziomie abstrakcji, ogólniejszy).

Copyright by Wojciech Kempa

Wielopoziomowe reguły asocjacyjne (2)

- Mówimy, że transakcja T **wspiera element** x , jeżeli $x \in T$ oraz x jest poprzednikiem dowolnego elementu $y \in T$ w taksonomii \mathcal{T} (w taksonomii zilustrowanej na Rysunku 3 np. poprzednikiem czekolady są słodycze, czyli element taksonomii o wyższym poziomie abstrakcji, ogólniejszy).
- Jeżeli L jest zbiorem rozpatrywanych produktów, to wielopoziomową regułę asocjacyjną definiujemy teraz jako relację $X \longrightarrow Y$ gdzie $X, Y \in L$, $X \cap Y = \emptyset$ oraz, dodatkowo, żaden element $y \in Y$ nie jest poprzednikiem żadnego elementu $x \in X$.

- Mówimy, że transakcja T **wspiera element** x , jeżeli $x \in T$ oraz x jest poprzednikiem dowolnego elementu $y \in T$ w taksonomii \mathcal{T} (w taksonomii zilustrowanej na Rysunku 3 np. poprzednikiem czekolady są słodycze, czyli element taksonomii o wyższym poziomie abstrakcji, ogólniejszy).
- Jeżeli L jest zbiorem rozpatrywanych produktów, to wielopoziomową regułę asocjacyjną definiujemy teraz jako relację $X \longrightarrow Y$ gdzie $X, Y \in L$, $X \cap Y = \emptyset$ oraz, dodatkowo, żaden element $y \in Y$ nie jest poprzednikiem żadnego elementu $x \in X$.
- Podobnie jak w przypadku reguł jednopoziomowych, przyjmuje się próg minimalnego wsparcia $min\ supp$ oraz próg minimalnej ufności $min\ conf$, które są jednakowe dla wszystkich reguł, niezależnie od tego, czy opisują one asocjacje na najniższym poziomie abstrakcji czy też na najwyższym poziomie.

Miary atrakcyjności reguł asocjacyjnych (1)

- W analizie asocjacji wprowadza się dwie podstawowe **miary atrakcyjności reguł asocjacyjnych**.

Copyright by Wojciech Kempa

Miary atrakcyjności reguł asocjacyjnych (1)

- W analizie asocjacji wprowadza się dwie podstawowe **miary atrakcyjności reguł asocjacyjnych**.
- Weźmy pod uwagę regułę $A \rightarrow B$. Miarę *interest*, określającą poziom współzależności obiektów (produktów) A i B , definiujemy w następujący sposób:

$$interest(A \rightarrow B) = interest(B \rightarrow A) = \frac{\mathbf{P}(AB)}{\mathbf{P}(A)\mathbf{P}(B)},$$

gdzie odpowiednie prawdopodobieństwa szacuje się na podstawie częstości względnych.

Miary atrakcyjności reguł asocjacyjnych (1)

- W analizie asocjacji wprowadza się dwie podstawowe **miary atrakcyjności reguł asocjacyjnych**.
- Weźmy pod uwagę regułę $A \rightarrow B$. Miarę *interest*, określającą poziom współzależności obiektów (produktów) A i B , definiujemy w następujący sposób:

$$interest(A \rightarrow B) = interest(B \rightarrow A) = \frac{\mathbf{P}(AB)}{\mathbf{P}(A)\mathbf{P}(B)},$$

gdzie odpowiednie prawdopodobieństwa szacuje się na podstawie częstości względnych.

- Jeżeli dla danej reguły miara ta przyjmuje wartość równą 1, to mówimy, że A i B są niezależne. W przypadku wartości mniejszych od 1 mówimy o **korelacji negatywnej**, a jeżeli $interest > 1$ – o **korelacji pozytywnej**.

Miary atrakcyjności reguł asocjacyjnych (2)

- Alternatywą dla miary *interest* jest miara *lift*. Dla binarnych reguł asocjacyjnych jest ona równoważna mierze *interest*.

Copyright by Wojciech Kempa

Miary atrakcyjności reguł asocjacyjnych (2)

- Alternatywą dla miary *interest* jest miara *lift*. Dla binarnych reguł asocjacyjnych jest ona równoważna mierze *interest*.
- Definiujemy ją w następujący sposób:

$$lift(A \rightarrow B) = \frac{conf(A \rightarrow B)}{supp(B)}.$$

Copyright by Wojciech Kempa

Miary atrakcyjności reguł asocjacyjnych (2)

- Alternatywą dla miary *interest* jest miara *lift*. Dla binarnych reguł asocjacyjnych jest ona równoważna mierze *interest*.
- Definiujemy ją w następujący sposób:

$$lift(A \rightarrow B) = \frac{conf(A \rightarrow B)}{supp(B)}.$$

- W praktyce w ocenie reguł asocjacyjnych stosuje się także alternatywną postać współczynnika korelacji liniowej Pearsona, mianowicie

$$\varrho = \frac{\mathbf{P}(AB) - \mathbf{P}(A)\mathbf{P}(B)}{\sqrt{\mathbf{P}(A)\mathbf{P}(B)\mathbf{P}(\sim A)\mathbf{P}(\sim B)}},$$

gdzie odpowiednie prawdopodobieństwa szacuje się na podstawie częstości względnych.

Odkrywanie wzorców sekwencji (1)

- Istotą **analizy sekwencji** jest wykrywanie pewnych, powtarzających się często, specyficznych zachowań klientów. Jeśli wyjściowe dane miałyby charakter ilościowy, analiza sekwencji „wchodziłaby” w obszar zainteresowań analizy szeregów czasowych.

Copyright by Wojciech Kempa

Odkrywanie wzorców sekwencji (1)

- Istotą **analizy sekwencji** jest wykrywanie pewnych, powtarzających się często, specyficznych zachowań klientów. Jeśli wyjściowe dane miałyby charakter ilościowy, analiza sekwencji „wchodziłaby” w obszar zainteresowań analizy szeregów czasowych.
- Wyjściową bazę danych tworzą jednak **ciągi transakcji**, a zatem zdarzenia związane z konkretnymi decyzjami klientów analizowane w pewnym okresie czasu.

Copyright by Wojciech Kempa

Odkrywanie wzorców sekwencji (1)

- Istotą **analizy sekwencji** jest wykrywanie pewnych, powtarzających się często, specyficznych zachowań klientów. Jeśli wyjściowe dane miałyby charakter ilościowy, analiza sekwencji „wchodziłaby” w obszar zainteresowań analizy szeregów czasowych.
- Wyjściową bazę danych tworzą jednak **ciągi transakcji**, a zatem zdarzenia związane z konkretnymi decyzjami klientów analizowane w pewnym okresie czasu.
- Efektywna analiza sekwencji pozwala na skuteczną predykcję zachowań klientów w przyszłości, a tym samym jest pomocna w uzyskaniu odpowiedzi na wiele pytań kluczowych z punktu widzenia marketingowego.

Copyright by Wojciech Kempa

Odkrywanie wzorców sekwencji (1)

- Istotą **analizy sekwencji** jest wykrywanie pewnych, powtarzających się często, specyficznych zachowań klientów. Jeśli wyjściowe dane miałyby charakter ilościowy, analiza sekwencji „wchodziłaby” w obszar zainteresowań analizy szeregów czasowych.
- Wyjściową bazę danych tworzą jednak **ciągi transakcji**, a zatem zdarzenia związane z konkretnymi decyzjami klientów analizowane w pewnym okresie czasu.
- Efektywna analiza sekwencji pozwala na skutecną predykcję zachowań klientów w przyszłości, a tym samym jest pomocna w uzyskaniu odpowiedzi na wiele pytań kluczowych z punktu widzenia marketingowego.
- Na przykład: z jakim prawdopodobieństwem klient, który kupił artykuł A , a po jakimś czasie artykuł B , będzie skłonny nabyć w najbliższej przyszłości artykuł C ?

Odkrywanie wzorców sekwencji (2)

- Analiza sekwencji znajduje zastosowanie np. w przewidywaniu występowania kataklizmów i klęsk żywiołowych (jaka sekwencja zdarzeń do nich prowadzi), w medycynie (w analizie poszczególnych jednostek chorobowych poprzez obserwację ciągu następujących po sobie objawów, w badaniu efektywności terapii farmakologicznej, analizie skutków ubocznych stosowania danego leku), na rynku usług telekomunikacyjnych (sekwencja zdarzeń prowadzących do zmiany operatora) itp.

Odkrywanie wzorców sekwencji (2)

- Analiza sekwencji znajduje zastosowanie np. w przewidywaniu występowania kataklizmów i klęsk żywiołowych (jaka sekwencja zdarzeń do nich prowadzi), w medycynie (w analizie poszczególnych jednostek chorobowych poprzez obserwację ciągu następujących po sobie objawów, w badaniu efektywności terapii farmakologicznej, analizie skutków ubocznych stosowania danego leku), na rynku usług telekomunikacyjnych (sekwencja zdarzeń prowadzących do zmiany operatora) itp.
- Niech $L = \{l_1, \dots, l_m\}$ będzie pewnym zbiorem elementów.

Odkrywanie wzorców sekwencji (2)

- Analiza sekwencji znajduje zastosowanie np. w przewidywaniu występowania kataklizmów i klęsk żywiołowych (jaka sekwencja zdarzeń do nich prowadzi), w medycynie (w analizie poszczególnych jednostek chorobowych poprzez obserwację ciągu następujących po sobie objawów, w badaniu efektywności terapii farmakologicznej, analizie skutków ubocznych stosowania danego leku), na rynku usług telekomunikacyjnych (sekwencja zdarzeń prowadzących do zmiany operatora) itp.
- Niech $L = \{l_1, \dots, l_m\}$ będzie pewnym zbiorem elementów.
- Sekwencją** S nazywamy uporządkowaną listę (ciąg transakcji) $S = (T_1, \dots, T_n)$, gdzie $T_i \subseteq L$, $T_i \neq \emptyset$.

Odkrywanie wzorców sekwencji (2)

- Analiza sekwencji znajduje zastosowanie np. w przewidywaniu występowania kataklizmów i klęsk żywiołowych (jaka sekwencja zdarzeń do nich prowadzi), w medycynie (w analizie poszczególnych jednostek chorobowych poprzez obserwację ciągu następujących po sobie objawów, w badaniu efektywności terapii farmakologicznej, analizie skutków ubocznych stosowania danego leku), na rynku usług telekomunikacyjnych (sekwencja zdarzeń prowadzących do zmiany operatora) itp.
- Niech $L = \{l_1, \dots, l_m\}$ będzie pewnym zbiorem elementów.
- Sekwencją** S nazywamy uporządkowaną listę (ciąg transakcji) $S = (T_1, \dots, T_n)$, gdzie $T_i \subseteq L$, $T_i \neq \emptyset$.
- Zbiór $T_i = \{x_1, \dots, x_k\}$, gdzie $x_j \in L$, $1 \leq j \leq k$, nazywamy *i-tym wyrazem sekwencji*.

Odkrywanie wzorców sekwencji (2)

- Analiza sekwencji znajduje zastosowanie np. w przewidywaniu występowania kataklizmów i klęsk żywiołowych (jaka sekwencja zdarzeń do nich prowadzi), w medycynie (w analizie poszczególnych jednostek chorobowych poprzez obserwację ciągu następujących po sobie objawów, w badaniu efektywności terapii farmakologicznej, analizie skutków ubocznych stosowania danego leku), na rynku usług telekomunikacyjnych (sekwencja zdarzeń prowadzących do zmiany operatora) itp.
- Niech $L = \{l_1, \dots, l_m\}$ będzie pewnym zbiorem elementów.
- Sekwencją** S nazywamy uporządkowaną listę (ciąg transakcji) $S = (T_1, \dots, T_n)$, gdzie $T_i \subseteq L$, $T_i \neq \emptyset$.
- Zbiór $T_i = \{x_1, \dots, x_k\}$, gdzie $x_j \in L$, $1 \leq j \leq k$, nazywamy **i -tym wyrazem sekwencji**.
- Dowolny element x_j występuje tylko raz w pojedynczym wyrazie, ale może wystąpić w wielu wyrazach.

- Mówimy, że wyraz T **wspiera** $x \in L$, jeżeli $x \in T$.

Copyright by Wojciech Kempa

Odkrywanie wzorców sekwencji (3)

- Mówimy, że wyraz T **wspiera** $x \in L$, jeżeli $x \in T$.
- Mówimy, że wyraz T **wspiera zbiór** $X \subseteq L$, jeżeli wspiera każdy element tego zbioru.

Copyright by Wojciech Kempa

- Mówimy, że wyraz T **wspiera** $x \in L$, jeżeli $x \in T$.
- Mówimy, że wyraz T **wspiera zbiór** $X \subseteq L$, jeżeli wspiera każdy element tego zbioru.
- Liczbę wyrazów sekwencji S nazywamy **długością sekwencji**. Sekwencję o długości k nazywamy **k -sekwencją**.

Copyright by Wojciech Kempa

- Mówimy, że wyraz T **wspiera** $x \in L$, jeżeli $x \in T$.
- Mówimy, że wyraz T **wspiera zbiór** $X \subseteq L$, jeżeli wspiera każdy element tego zbioru.
- Liczbę wyrazów sekwencji S nazywamy **długością sekwencji**. Sekwencję o długości k nazywamy **k -sekwencją**.
- **Rozmiarem sekwencji** S nazywamy liczbę wystąpień pojedynczych elementów x_j w tej sekwencji.

Odkrywanie wzorców sekwencji (3)

- Mówimy, że wyraz T **wspiera** $x \in L$, jeżeli $x \in T$.
- Mówimy, że wyraz T **wspiera zbiór** $X \subseteq L$, jeżeli wspiera każdy element tego zbioru.
- Liczbę wyrazów sekwencji S nazywamy **długością sekwencji**. Sekwencję o długości k nazywamy **k -sekwencją**.
- **Rozmiarem sekwencji** S nazywamy liczbę wystąpień pojedynczych elementów x_j w tej sekwencji.
- Na przykład, rozmiar sekwencji

$$\langle (2)(4, 5)(7, 8, 9)(3, 6, 7) \rangle$$

wynosi 9, a jej długość jest równa 4.

Odkrywanie wzorców sekwencji (4)

- Mówimy, że sekwencja $\langle X_1, \dots, X_n \rangle$ zawiera się w sekwencji $\langle Y_1, \dots, Y_m \rangle$, jeżeli

$$\exists_{i_1 < i_2 < \dots < i_n} : X_i \subseteq Y_{i_1}, X_2 \subseteq Y_{i_2}, \dots, X_n \subseteq Y_{i_n}.$$

Odkrywanie wzorców sekwencji (4)

- Mówimy, że sekwencja $\langle X_1, \dots, X_n \rangle$ zawiera się w sekwencji $\langle Y_1, \dots, Y_m \rangle$, jeżeli

$$\exists_{i_1 < i_2 < \dots < i_n} : X_i \subseteq Y_{i_1}, X_2 \subseteq Y_{i_2}, \dots, X_n \subseteq Y_{i_n}.$$

- Na przykład, sekwencja $S = \langle (4)(6, 7)(9) \rangle$ zawiera się w sekwencji $Q = \langle (3, 4)(4, 7, 8)(6, 7, 8, 9)(2, 9)(5, 6) \rangle$.

Odkrywanie wzorców sekwencji (5)

- Mówimy, że S jest sekwencją **maksymalną**, jeżeli nie zawiera się w żadnej innej sekwencji.

Copyright by Wojciech Kempa

Odkrywanie wzorców sekwencji (5)

- Mówimy, że S jest sekwencją **maksymalną**, jeżeli nie zawiera się w żadnej innej sekwencji.
- Zbiór sekwencji $D_S = (S_1, \dots, S_n)$ nazywamy **bazą danych sekwencji**.

Copyright by Wojciech Kempa

Odkrywanie wzorców sekwencji (5)

- Mówimy, że S jest sekwencją **maksymalną**, jeżeli nie zawiera się w żadnej innej sekwencji.
- Zbiór sekwencji $D_S = (S_1, \dots, S_n)$ nazywamy **bazą danych sekwencji**.
- Mówimy, że $S \in D_S$ **wspiera** sekwencję Q , jeżeli Q zawiera się w S .

Copyright by Wojciech Kempa

Odkrywanie wzorców sekwencji (5)

- Mówimy, że S jest sekwencją **maksymalną**, jeżeli nie zawiera się w żadnej innej sekwencji.
- Zbiór sekwencji $D_S = (S_1, \dots, S_n)$ nazywamy **bazą danych sekwencji**.
- Mówimy, że $S \in D_S$ **wspiera** sekwencję Q , jeżeli Q zawiera się w S . Copyright by Wojciech Kempa
- Definiujemy **wsparcie sekwencji** S w bazie danych D_S w następujący sposób:

$$supp(S) = \frac{|\{S_i \in D_S : S_i \text{ wspiera } S\}|}{|D_S|}.$$

Odkrywanie wzorców sekwencji (6)

- Zasadniczym celem procesu analizy sekwencji jest znalezienie wszystkich sekwencji, których wsparcie w bazie D_S jest co najmniej równe pewnej minimalnej wartości wsparcia $\min supp.$

Copyright by Wojciech Kempa

Odkrywanie wzorców sekwencji (6)

- Zasadniczym celem procesu analizy sekwencji jest znalezienie wszystkich sekwencji, których wsparcie w bazie D_S jest co najmniej równe pewnej minimalnej wartości wsparcia $\min supp$.
- Takie sekwencje nazywamy **sekwencjami częstymi** lub **wzorcami sekwencji**.

Odkrywanie wzorców sekwencji (6)

- Zasadniczym celem procesu analizy sekwencji jest znalezienie wszystkich sekwencji, których wsparcie w bazie D_S jest co najmniej równe pewnej minimalnej wartości wsparcia $\min supp$.
- Takie sekwencje nazywamy **sekwencjami częstymi** lub **wzorcami sekwencji**.
- Sekwencje częste, które równocześnie są sekwencjami maksymalnymi nazywamy **maksymalnymi wzorcami sekwencji**.

- Podstawowy algorytm odkrywania wzorców sekwencji, **algorytm AprioriAll**, sformułowany w 1995 roku, jest rozszerzeniem algorytmu Apriori, wykorzystywanego w analizie asocjacji i również wykorzystuje własność antymonotoniczności miary wsparcia.

Copyright by Wojciech Kempa

- Podstawowy algorytm odkrywania wzorców sekwencji, **algorytm AprioriAll**, sformułowany w 1995 roku, jest rozszerzeniem algorytmu Apriori, wykorzystywanego w analizie asocjacji i również wykorzystuje własność antymonotoniczności miary wsparcia.
- Rzeczywiście, jeśli sekwencja X nie jest wzorcem sekwencji (nie jest sekwencją częstą), to żadna sekwencja Y zawierająca X nie może być wzorcem sekwencji. Mamy bowiem

$$X \subseteq Y \implies supp(Y) \leq supp(X).$$

Ogólny schemat odkrywania wzorców sekwencji

Ogólny schemat odkrywania wzorców sekwencji wygląda w następujący sposób:

- ① **sortowanie** – sortujemy bazę danych D do postaci bazy danych sekwencji D_S ;
- ② **znajdowanie zbiorów częstych** – znajdujemy wszystkie zbiory częste w bazie D_S ;
- ③ **transformacja** – przyporządkowujemy każdemu wyrazowi T należącemu do danej sekwencji listę zbiorów częstych zawierających się w tym wyrazie;
- ④ **sekwencjonowanie** – stosując algorytm AprioriAll, znajdujemy w D_S sekwencje częste (wzorce sekwencji);
- ⑤ **maksymalizacja** – w zbiorze znalezionych wzorców sekwencji znajdujemy maksymalne wzorce sekwencji (jest to krok opcjonalny).

W algorytmie AprioriAll (podobnie, jak to było w algorytmie Apriori) generujemy k -sekwencje kandydujące na podstawie $(k - 1)$ -sekwencji częstych. Ma to miejsce w dwóch etapach.

- W **etapie połączenia** łączymy dwie sekwencje ze zbioru LS_{k-1} (czyli zbioru $(k - 1)$ -sekwencji częstych) w celu wygenerowania k -sekwencji kandydującej (elementu zbioru CS_k). Warunkiem połączenia dwóch sekwencji z LS_{k-1} jest zgodność $k - 2$ wyrazów obu sekwencji.
- W **etapie eliminacji** usuwamy wszystkie sekwencje kandydujące $S \in CS_k$ takie, dla których istnieją $(k - 1)$ -podsekwencje sekwencji S nienależące do LS_{k-1} .